

國 立 中 央 大 學

資訊工程學系
碩士論文

基於深度學習之嬰兒危險偵測系統

A Deep-learning-based Danger Detection System
for Infant

研 究 生：王佳君
指 導 教 授：蘇木春 博 士

中 華 民 國 一 百 一 十 一 年 六 月

國立中央大學圖書館學位論文授權書

填單日期： 111 / 06 / 30

2019.9 版

授權人姓名	王佳君	學 號	109522116
系所名稱	資訊工程學系碩士班	學位類別	<input checked="" type="checkbox"/> 碩士 <input type="checkbox"/> 博士
論文名稱	基於深度學習之嬰兒危險偵測系統	指導教授	蘇木春

學位論文網路公開授權

授權本人撰寫之學位論文全文電子檔：

- 在「國立中央大學圖書館博碩士論文系統」.

() 同意立即網路公開

() 同意 於西元 _____ 年 _____ 月 _____ 日網路公開

() 不同意網路公開，原因是： _____

- 在國家圖書館「臺灣博碩士論文知識加值系統」

() 同意立即網路公開

() 同意 於西元 _____ 年 _____ 月 _____ 日網路公開

() 不同意網路公開，原因是： _____

依著作權法規定，非專屬、無償授權國立中央大學、台灣聯合大學系統與國家圖書館，不限地域、時間與次數，以文件、錄影帶、錄音帶、光碟、微縮、數位化或其他方式將上列授權標的基於非營利目的進行重製。

學位論文紙本延後公開申請 (紙本學位論文立即公開者此欄免填)

本人撰寫之學位論文紙本因以下原因將延後公開

- 延後原因

() 已申請專利並檢附證明，專利申請案號：

() 準備以上列論文投稿期刊

() 涉國家機密

() 依法不得提供，請說明： _____

- 公開日期：西元 _____ 年 _____ 月 _____ 日

※繳交教務處註冊組之紙本論文(送繳國家圖書館)若不立即公開，請加填「國家圖書館學位論文延後公開申請書」

研究生簽名：_____

指導教授簽名：_____

國立中央大學碩士班研究生
論文指導教授推薦書

資訊工程 學系/研究所 王佳君 研究生所
提之論文 基於深度學習之嬰兒危險偵測系統 係
由本人指導撰述，同意提付審查。

指導教授_____ (簽章)

111 年 06 月 30 日

國立中央大學碩士班研究生
論文口試委員審定書

資訊工程 學系/研究所 王佳君 研究生所
提之論文 基於深度學習之嬰兒危險偵測系統 經
本委員會審議，認定符合碩士資格標準。

學位考試委員會召集人 _____

委 員 _____

中 華 民 國 111 年 06 月 30 日

基於深度學習之嬰兒危險偵測系統

摘要

嬰兒照護者在照顧嬰兒時，可能發生無法隨時關注嬰兒狀態的情形，使得嬰兒因溢奶、翻身、趴睡等情形，致使呼吸不順而發生憾事。

又因現有產品多用感測器偵測嬰兒狀態，功能單一且多有使用限制，便利性不佳。

因此，本論文提出基於深度學習技術，專注於嬰兒影像畫面進行臉部遮擋及姿勢辨識之危險偵測系統：利用 ResNet50 網路訓練模型，以分析嬰兒臉部是否遭異物遮蔽及辨識四種基礎姿勢：正躺、趴躺、坐姿及站立。

兩部分之辨識精確度皆達 98%。

故當系統輸入嬰兒影片時，可透過模型辨識嬰兒的姿勢可能處於危險狀態或臉部遭異物遮擋，則可即時警示照護者。

由於目前未有公開之嬰兒資料集，故本文中所使用的嬰兒照片皆為網路圖片及影片進行擷取並前處理而成。

關鍵字：嬰兒危險偵測，嬰兒臉部辨識，深度學習，嬰兒猝死症

A Deep-learning-based Danger Detection System for Infant

Abstract

When taking care of the infant, the baby caregiver may not be able to pay attention to the status of the baby at any time, which may cause the infant to suffer from unpleasant breathing due to overflowing milk, turning over, sleeping on the stomach, etc.

In addition, the existing products use multiple sensors to detect the state of the infant, which has a single function and many restrictions on use, resulting in poor convenience.

Therefore, this paper proposes a danger detection system based on deep learning technology, focusing on face occlusion and gesture recognition of baby images: The ResNet50 network is used to train the model to analyze whether the infant's face is obscured by foreign objects and recognize four basic postures: lying, lying on the stomach, sitting and standing.

The recognition accuracy of both parts is 98%.

Therefore, when the system inputs a infant video, the model can recognize that the infant's posture may be in a dangerous state or the face is covered by a foreign object, and the caregiver can be immediately alerted.

Since there is currently no public infant data set, the infant photos used in this article are all captured and pre-processed from online pictures and videos.

Keywords: Infant danger detection, Infant face detection, Deep learning, Sudden infant death syndrome

誌謝

就讀碩士班期間，接受了很多人的幫助與鼓勵，非常感謝這兩年的所有時光。

首先，感謝蘇木春老師的指導，在研究上給予了我很多的方向與教學，讓我在碩士期間獲益良多；也感謝蘇老師很信任學生，讓我在這兩年得以很好的妥善規劃時間。

接著，感謝實驗室的每位成員，讓我在 CILAB 擁有這麼珍貴的回憶。感謝佳菁、小花、熙琪、小烏龜，處理實驗室繁忙的事務，讓我們可以有這麼舒適的研究環境；感謝威任學長、偉倫學長，在研究中提供了很多想法，讓我在研究中能有更明確的方向；感謝子謙學長、政育學長、映如學姊、書仔學姊，在我有疑惑的時候，解答了許多的問題，帶領我們熟悉實驗室的生活；感謝鈞翔、昌翰、逸星、奕蘋、詩勻，交流彼此的意見與想法，讓我能激發出更多不同的思維；感謝智穎、景豐、季劫、譽鈞、姿瑩，一起參與了許多實驗室的事務，讓所有活動及計畫得以完成。

最後，也感謝我的家人、朋友、愛人以及我自己，在不同的人生階段中一起度過，給予我非常多的支撐與幫助，而得以逐漸成長為一位更成熟的個體。

目錄

	頁次
摘要	iv
Abstract	v
誌謝	vii
目錄	viii
一、 緒論	1
1.1 研究動機	1
1.2 研究目的	2
1.3 論文架構	3
二、 背景知識以及文獻回顧	4
2.1 背景知識	4
2.1.1 電腦斷層掃描	4
2.1.2 Hounsfield Units.....	5
2.1.3 心臟冠狀動脈結構	6
2.1.4 3D U-Net	7
2.1.5 CycleGAN.....	7
2.2 文獻回顧	8
2.2.1 對於有顯影劑增強之電腦斷層影像進行冠狀動脈分 割之研究	8
2.2.2 對於無顯影劑增強之電腦斷層影像進行分割之研究 ...	9

2.2.3 將 GAN 應用於醫學影像之研究	10
三、 研究方法	11
3.1 資料前處理	11
3.1.1 擷取 HU 值範圍.....	11
3.1.2 影像壓縮	13
3.2 無顯影劑影像資料擴增模型	13
3.3 冠狀動脈分割	14
3.4 有顯影劑冠狀動脈分割之相關應用	15
3.4.1 鈣化位置偵測	15
3.4.2 狹窄度分析	17
3.4.3 資料視覺化	19
四、 實驗設計與結果	21
4.1 資料集	21
4.2 有顯影劑增強影像之冠狀動脈分割	22
4.3 電腦斷層掃描影像風格轉換	26
4.4 無顯影劑增強影像之冠狀動脈分割	27
4.5 相關應用及視覺化	31
4.5.1 取得血管分析結果	31
4.5.2 鈣化位置分析	32
4.5.3 狹窄度分析	33
五、 總結	36
5.1 結論	36
5.2 未來展望	37

圖 目 錄

頁 次

2.1	心臟冠狀動脈結構	6
2.2	3D U-Net	7
2.3	CycleGAN	8
3.1	有顯影劑增強之電腦斷層掃描影像原始數值範圍	11
3.2	有顯影劑增強之電腦斷層影像數值調整	12
3.3	無顯影劑增強之電腦斷層影像數值調整	12
3.4	有無顯影劑增強之電腦斷層影像	14
3.5	冠狀動脈疾病風險評估流程	16
3.6	僅以有顯影劑資料進行鈣化位置偵測流程	17
3.7	狹窄度分析流程	18
3.8	細線化處理取得中心線	18
3.9	以血管中心線拉直之原始影像	18
3.10	以血管中心線拉直之冠狀動脈分割	19
3.11	3D Slicer 軟體介面	20
3.12	3D Slicer 自定義套件	20
4.1	模型訓練資料範例-有顯影劑增強	22
4.2	模型分割錯誤範例	24
4.3	模型分類錯誤範例	24
4.4	有顯影劑增強之電腦斷層掃描分割較佳結果範例	25

4.5 有顯影劑增強之電腦斷層掃描分割較差結果範例	26
4.6 原始影像與 CycleGAN 轉換結果範例	27
4.7 模型訓練資料範例-無顯影劑增強	28
4.8 有無使用 CycleGAN 進行資料擴增之模型輸出結果	29
4.9 無顯影劑增強之電腦斷層掃描分割較佳結果-範例 1	30
4.10 無顯影劑增強之電腦斷層掃描分割較佳結果-範例 2	30
4.11 無顯影劑增強之電腦斷層掃描分割較差結果範例	31
4.12 本研究開發之套件介面-冠狀動脈分割	31
4.13 3D Slicer 冠狀動脈分割結果視覺化	32
4.14 本研究開發之套件介面-鈣化位置分析	33
4.15 3D Slicer 鈣化位置視覺化	33
4.16 本研究開發之套件介面-狹窄度分析	34
4.17 冠狀動脈以中心線重組	34
4.18 冠狀動脈血管管徑趨勢	35
4.19 無顯影劑影像分割之 RCA 以中心線重組	35

表 目 錄

頁 次

2.1	頭部電腦斷層掃描常見組織之 HU 值對照表 levCTAngiographyCT2002	5
2.2	頭部電腦斷層掃描常見之 HU 值 Window 預設值 levCTAngiographyCT2002	5
3.1	原始影像大小及壓縮後大小	13
4.1	有顯影劑增強之電腦斷層掃描 7-Fold 交叉驗證結果	23
4.2	有顯影劑增強之電腦斷層掃描分割結果與其他研究比較	25
4.3	無顯影劑增強之電腦斷層掃描分割結果-僅使用原始資料	29
4.4	無顯影劑增強之電腦斷層掃描分割結果-使用 CycleGAN 進行資料擴增	29

一、緒論

1.1 研究動機

在嬰兒照護時，難免發生照顧者視線離開嬰兒的情形，如：泡奶、做飯、上廁所等，無法百分之百關注嬰兒的各種行為，而若此時嬰兒發生溢奶、物品遮蓋口鼻、自行翻身或站立等情形，對嬰兒具危險性而可能導致憾事發生。

根據衛生福利部統計處所發布的嬰兒主要死因統計 [1] 中，101 年至 105 年間每年至少 30 位嬰兒死於嬰兒猝死症候群（Sudden infant death syndrome，簡稱 SIDS），106 年至 109 年雖死亡數減少，但每年仍有超過 20 位嬰兒因此逝世，為嬰兒十大死亡原因之一。

三軍總醫院對於嬰兒猝死症的說明為：一個原本無異狀的嬰兒，突然且無法預期的死亡，常發生在嬰兒睡眠時，並在事後的屍體解剖檢查中找不到其真正致死原因。凡未滿一歲的嬰幼兒皆可能發生，其中二至四個月時期尤為常見，亦可能發生在嬰兒出生一兩周內。然而，目前對於嬰兒猝死症的成因仍不清楚，綜合醫界目前相關因素的研究中，包含了嬰兒因溢奶或嘔吐產生呼吸道緊縮反射及憋氣，或因翻身、趴睡致使呼吸困難，而窒息死亡等原因。

國內外有許多為自動化監測嬰兒狀態之研究，大多透過感測器來量測嬰兒之特定危險狀態，這些監測方式具單一性，若欲增加其他功能則須裝設更多的感測器，不僅可能影響嬰兒之活動，亦可能產生更多潛在的危險性，如：嬰兒誤食裝置、裝置纏繞嬰兒等。

因此，我們認為直接透過攝影機拍攝嬰兒影像畫面，辨識嬰兒狀態以進行危險偵測，不但能同時偵測多種不同危險情境，亦可以減少干擾嬰兒行為，並免除更多的潛在危險。

1.2 研究目的

本研究利用 ResNet50 進行嬰兒動作及臉部遮擋之辨識，且透過 DeepFace 演算法前處理嬰兒影像以擷取嬰兒臉部影像畫面，而得以對嬰兒進行危險偵測。

本研究預計達成以下目標：

- 針對嬰兒姿勢，判斷嬰兒是否處於趴睡或站立姿勢，而有潛在危險發生。
- 針對嬰兒臉部，判斷嬰兒是否因嘔吐物、毛巾等外物遮蓋其口鼻，而可能使嬰兒發生窒息危機。

1.3 論文架構

本論文分為五個章節，其架構如下：

第一章、緒論，敘述本論文之研究動機、研究目的及論文架構。

第二章、相關研究，探討近年與嬰兒偵測之相關研究，並敘述本研究之背景知識，如：嬰兒猝死症及利用之深度學習模型架構。

第三章、研究方法，說明本研究之詳細內容，如：資料集之分類定義及前處理、以及完整系統之流程說明。

第四章、實驗設計與結果，說明實驗設計內容以及評估方法，並對於實驗結果進行探討。

第五章、結論與未來展望，對於研究結果進行總結，並討論研究的未來展望。

二、背景知識以及文獻回顧

2.1 背景知識

2.1.1 電腦斷層掃描

電腦斷層掃描 (Computed Tomography, CT) **nadrljanskiComputedTomographyRmckavanaghEssentialsCardiacComputerized2015** 是目前廣泛運用的一種非侵入性醫療檢查，與 X 射線相同，電腦斷層掃描以測量組織的密度進行成像，因此影像中越亮的部分代表密度越高，反之則代表密度越低。透過將電腦斷層掃描的二維影像進行堆疊可以獲得身體的三維結構，使得醫師能夠利用非侵入性的方式取得受檢者身體內部的結構。

運用電腦斷層掃描於心臟冠狀動脈檢查時，通常會搭配顯影劑的使用，將含碘的顯影劑注射至受檢者的血液，以增加電腦斷層影像中血液流經處與其他組織間的對比度。然而，目前已知電腦斷層顯影劑具有腎毒性 **andreucciUpdateRenalToxicity2017**，腎功能不全者、糖尿病使用 Metformin 成分藥物者 **rasuliMetforminContrastMedia1998** 皆不適合使用。此外，電腦斷層顯影劑有 5-8% 的人可能會過敏 **saljoughianIntravenousRadiocontrastAgents2013**，症狀從輕症的潮紅、嘔吐，到致命的休克都有。此類受檢者不適合拍攝有顯影劑增強之電腦斷層影像，因此如何達成運用未注射顯影劑的電腦斷層影像進行血管分割是本研究的目標之一。

2.1.2 Hounsfield Units

Hounsfield Units(HU) greenwayHounsfieldUnitRadiology, levCTAngiographyCT murphyWindowingCTRadiology 為電腦斷層掃描影像標準化後的數值單位，是由測量後的衰減係數經過線性轉換後獲得，其中在標準溫度以及標準壓力下，蒸餾水被定義為 0 HU，空氣被定義為-1000 HU，HU 值計算的公式為式 (2.1)，其中 μ_{tissue} 為測量組織的衰減係數、 μ_{water} 為蒸餾水的衰減係數。

$$HU = 1000 \times (\mu_{tissue} - \mu_{water}) / \mu_{water} \quad (2.1)$$

表 2.1為頭部電腦斷層掃描中，常見組織對應的 HU 值：

表 2.1: 頭部電腦斷層掃描常見組織之 HU 值對照表 levCTAngiographyCT2002

Hounsfield units	Tissue
>1000	Bone, calcium, metal
100 to 600	Iodinated CT contrast
30 to 500	Punctate calcifications
60 to 100	Intracranial hemorrhage
35	Gray matter
25	White matter
20 to 40	Muscle, soft tissue
0	Water
-30 to -70	Fat
<-1000	Air

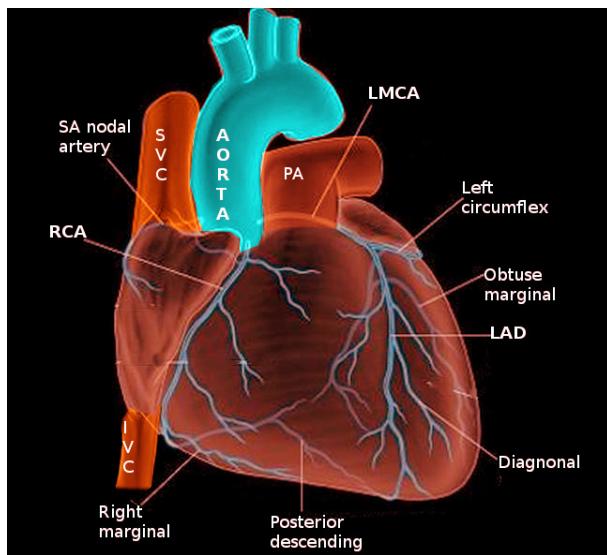
此外，由於 HU 值的範圍通常十分龐大，導致原始影像對比度較差，因此在觀察電腦斷層影像時，通常會針對不同觀察目標設定對應的上下界，將下界之 HU 值視為最暗、上界之 HU 值視為最亮，使得能夠更清楚的觀察目標，表 2.2為頭部電腦斷層掃描中，常見預設 HU 上下界設定值，以軟組織 (Soft tissue) 為例，中心點為 0 HU、寬度為 350 HU，即是下界為-175 HU，上界為 175 HU，不過表 2.2僅為參考之預設值，實際使用時會依照需求進行細部調整。

表 2.2: 頭部電腦斷層掃描常見之 HU 值 Window 預設值 levCTAngiographyCT2002

Setting name	Center level(HU)	Window width(HU)
Routine head	30	80
Acute stroke	30	300
Skull	250	4000
Subdural hematoma	65	130
CTA	150	450
Soft tissue	0	350
Lung	-500	1500

2.1.3 心臟冠狀動脈結構

心臟冠狀動脈 **ogobuiroAnatomyThoraxHeart2021, rehmanPhysiologyCoronaryArteries2021** 構如圖 2.1，冠狀動脈與主動脈 (Aorta) 相連接並可以分為左右兩邊，左邊以左主冠狀動脈 (Left Main Coronary Artery, LM) 開始，並可以再分為左前降支 (Left Anterior Descending, LAD) 以及左迴旋支 (Left Circumflex, LCx)；右邊則是以右冠狀動脈 (Right Coronary Artery, RCA) 為主。

圖 2.1: 心臟冠狀動脈結構 **ogobuiroAnatomyThoraxHeart2021**

冠狀動脈用來供應心肌含氧血，是維持心臟功能的重要血管，當動脈粥樣硬化 (Atherosclerosis) **AtherosclerosisAmericanHeart, AtherosclerosisNHLBI** 生在冠狀動脈時被稱為冠狀動脈心臟病，可能會導致心絞痛或心臟病的發生，當冠狀動脈阻塞時會導致心肌梗塞 **ojhaMyocardialInfarction2021**，

使得心肌無法獲得氧氣而產生缺氧，影響心臟運作功能。

2.1.4 3D U-Net

3D U-Net **cicek3DUNetLearning2016**是由 Çiçek 等人於 2016 年提出的 3D 版本 U-Net，架構與 Ronneberger 等人於 2015 提出之 U-Net 大致相同，差異處為將輸入改為 3D 影像，並增加了卷積層的 Kernel 數量以及 Batch Normalization，使得模型效果以及收斂速度能夠有所提升。圖 2.2 為 3D U-Net 的架構，

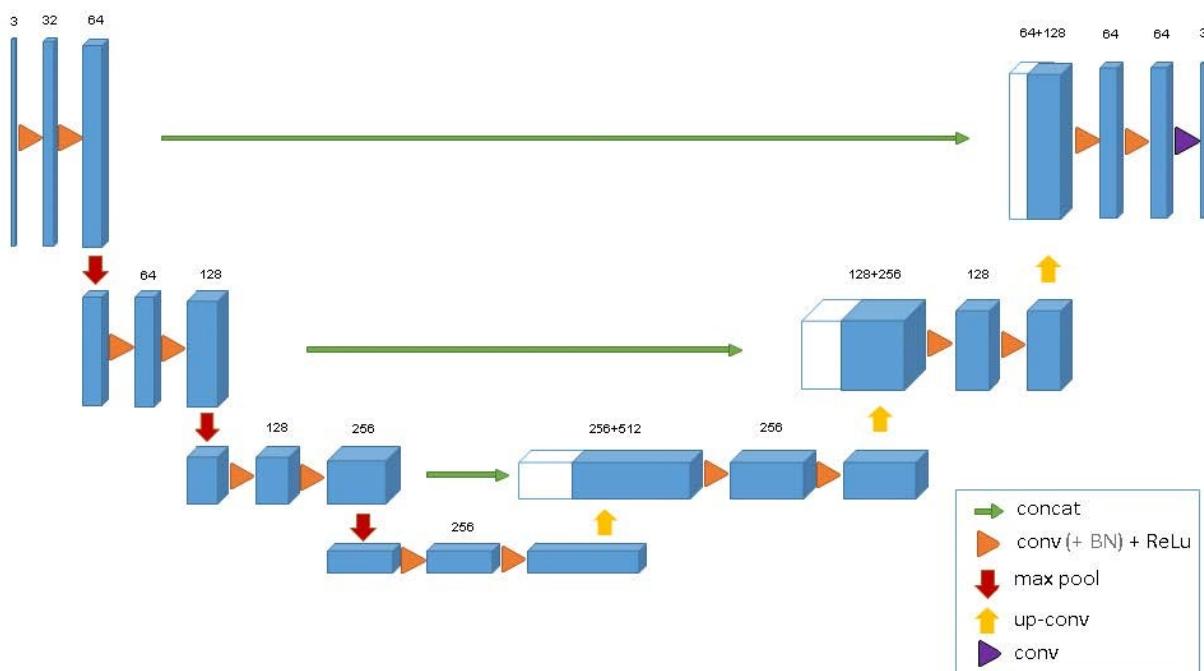
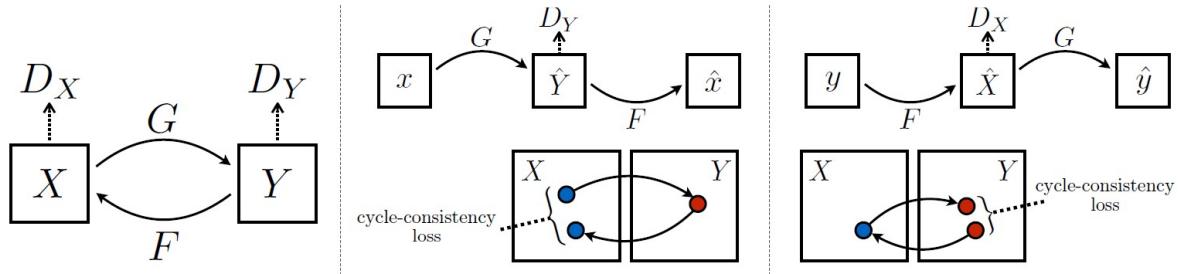


圖 2.2: 3D U-Net 模型架構 **cicek3DUNetLearning2016**

2.1.5 CycleGAN

CycleGAN **zhuUnpairedImagetoImageTranslation2017**是由 Zhu 等人於 2017 年提出的模型，為一個能夠透過非對稱資料集進行訓練，實現圖像生成、風格轉換的模型。模型架構如圖 2.3，其特色為有兩組 Generator 以及 Discriminator，用以將 Domain X 與 Domain Y 的影像互相轉換，並使用 cycle-consistency loss 避免模型在風格轉換時忽略原始影像的資訊。

圖 2.3: CycleGAN 模型架構 [zhuUnpairedImage-to-ImageTranslation2017](#)

本研究使用 CycleGAN 進行資料擴增，訓練一個能夠將有顯影劑增強之電腦斷層影像轉換為無顯影劑增強之影像的模型，藉以增強無顯影劑影像之血管分割任務的模型效果。

2.2 文獻回顧

2.2.1 對於有顯影劑增強之電腦斷層影像進行冠狀動脈分割之研究

Moeskops 等人 [moeskopsDeepLearningMultitask2016](#) 的研究使用 2D CNN 對於多種醫學影像任務進行分割，其中包含了對於有顯影劑電腦斷層影像進行冠狀動脈分割，其以目標體素 (Voxel) 中心，取 3 個不同解剖平面 $51*51$ 影像大小的 Patch 做為 CNN 輸入，預測該目標體素是否為冠狀動脈，並在測試資料中達到 Dice Coefficient 約 0.65 的結果。

Huang 等人 [huangCoronaryArterySegmentation2018](#) 利用 3D U-Net 進行有顯影劑增強之心臟電腦斷層影像進行冠狀動脈分割，實驗了兩種不同有、無中心線資料集進行冠狀動脈分割的差異，分別使用 $32*32*32$ 的 Patch 以及 $64*64*16$ 的 Patch 做為 3D U-Net 輸入，並在有中心線資料集獲得較好的結果，對於測試資料達到 Dice Coefficient 約 0.7755 的結果。

Chen 等人 [chenCoronaryArterySegmentation2019](#) 利用多通道的 3D

U-Net 進行冠狀動脈分割，輸入通道包含原始的影像以及利用血管增強濾鏡所取得的影像，且影像大小 32*32*32 的 Patch，該研究將輸出結果利用兩次取 Largest Connected Component(LCC)，藉此過濾出右冠狀動脈以及左冠狀動脈，減少一些錯誤分割的結果，對於測試資料集達到 Dice Coefficient 0.8060 的結果。

由文獻可以得知，目前已有許多對有顯影劑增強之電腦斷層影像進行冠狀動脈分割的研究，且在使用 3D CNN 模型的情況下能夠獲得較佳的結果，部分研究透過取得原始影像之額外特徵如中心線、血管增強濾鏡，或是使用後處理方法來增強冠狀動脈的分割結果。

2.2.2 對於無顯影劑增強之電腦斷層影像進行分割之研究

由於目前較少看到對於無顯影劑電腦斷層影像進行冠狀動脈分割的研究，因此本研究參考了一些非冠狀動脈分割的無顯影劑影像相關研究。

Shahzad 等人 **shahzadAutomaticSegmentationQuantification2017** 的研究使用了 multi-atlas-based 的分割方法，利用有顯影劑電腦斷層影像標記資料，並利用套合 (Registration) 方式對於無顯影劑電腦斷層影像進行心臟結構如全心臟、主動脈、左右心房及心室的分割，對於測試資料達到 Dice Coefficient 約 0.9 的結果。

Patel 等人 **patellIntracerebralHaemorrhageSegmentation2019** 的研究使用了使用兩組無顯影劑增強之腦部電腦斷層影像資料，並使用多通道的 3D CNN 對於腦部電腦斷層影像進行腦內出血的分割，對於測試資料中達到 Dice Coefficient 約 0.91 的結果。

Tuladhar 等人 **tuladharAutomaticSegmentationStroke2020** 的研究使用了無顯影劑增強之腦部電腦斷層影像，並利用 3D CNN 模型進行腦中風病灶的分割，在前處理時去除了腦部骨頭的結構，並以 Connected Component 分析去除較小的雜訊進行後處理，對於測試資料達到 Dice Coefficient 約 0.45 的結果。

由文獻可以得知，利用無顯影劑資料在部分分割研究中也能達到不錯的結果，然而目前所看到的文獻是對於較大型結構如心臟、出血病灶進行分割，與本研究對比度差且標記結構較小的冠狀動脈有些差距，相較之下本研究的分割目標較為困難，因此也較難達到上述研究的結果。

2.2.3 將 GAN 應用於醫學影像之研究

近年也有一些研究使用 GAN 模型對於醫學影像進行風格轉換，並應用於不同場景：

Jiang 等人 **jiangTumorAwareAdversarialDomain2018** 運用 CycleGAN 將電腦斷層掃描影像轉換為核磁共振影像，使用了考慮腫瘤的損失函數，使得 Cycle-GAN 轉換時能夠更好的保留腫瘤的資訊，並利用真實資料以及轉換出的虛擬核磁共振影像做為訓練資料集，訓練 U-Net 模型進行腫瘤分割，使得對於測試資料由僅使用原始資料 Dice Coefficient 約 0.55 的結果提升至 Dice Coefficient 約 0.80 的結果。

Welander 等人 **welanderGenerativeAdversarialNetworks2018** 的研究比較了兩種 GAN 模型 CycleGAN 以及 UNIT 對於 T1、T2 加權的 MRI 影像進行風格轉換的差異，並對於不同模型、資料的誤差進行分析及討論。

Song 等人 **songNoncontrastCTLiver2020** 的研究以無顯影劑電腦斷層影像進行肝臟的分割，其利用 CycleGAN 將有顯影劑的電腦斷層影像轉換為無顯影劑的電腦斷層影像做為額外的訓練資料，並使用 3D U-Net 訓練肝臟分割模型，使得對於測試資料由僅使用原始資料 Dice Coefficient 約 0.8826 的結果提升至 Dice Coefficient 約 0.9420 的結果。

以上文獻顯示了利用 GAN 進行醫學影像風格轉換的可能，由於本研究中已標記冠狀動脈之無顯影劑電腦斷層影像資料較少，因此本研究透過 GAN 產生更多的無顯影劑影像進行訓練，做為提升無顯影劑冠狀動脈模型效果的方法。

三、研究方法

3.1 資料前處理

3.1.1 撷取 HU 值範圍

由於電腦斷層掃描影像原始數值範圍較廣，如圖 3.1 所示，數值範圍分布於 -3000 HU 至 3000 HU，然而絕大部分除了 -3000 HU(掃描範圍外的背景)以外之數值皆分布在 -1000 HU 至 500 HU 的範圍，若直接使用此影像進行訓練，會因為輸入模型之影像對比度不佳，進而影響後續模型訓練的結果。圖 3.2a 為原始影像以灰階圖呈現的結果，可以看出其對於心臟結構以及冠狀動脈之對比度較差。

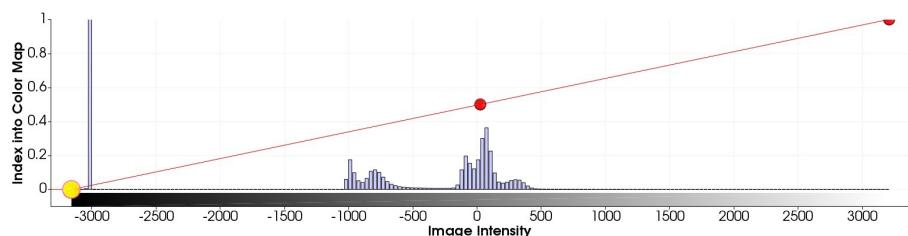


圖 3.1: 有顯影劑增強之電腦斷層掃描影像原始數值範圍

而在 -1000 HU 至 500 HU 的分布範圍中，分布於 -1000 HU 附近的數值為空氣，分布於 -700 HU 至 -600 HU 附近的數值為肺部，對於冠狀動脈分割較重要的部分如軟組織、顯影劑流經之血管、骨骼之範圍則是分布於 -300 HU 至 500 HU，因此本研究在資料前處理時，會將原始影像以下界 -300 HU 以及上界 500 HU 進行調整，超過下界數值設為下界，超過上界之數值設為上界，並進行標準化壓縮至 -1 至 1 的範圍，調整後之影像

以灰階圖呈現如圖 3.2b，可以看出其對於心臟結構以及冠狀動脈之對比度較佳。

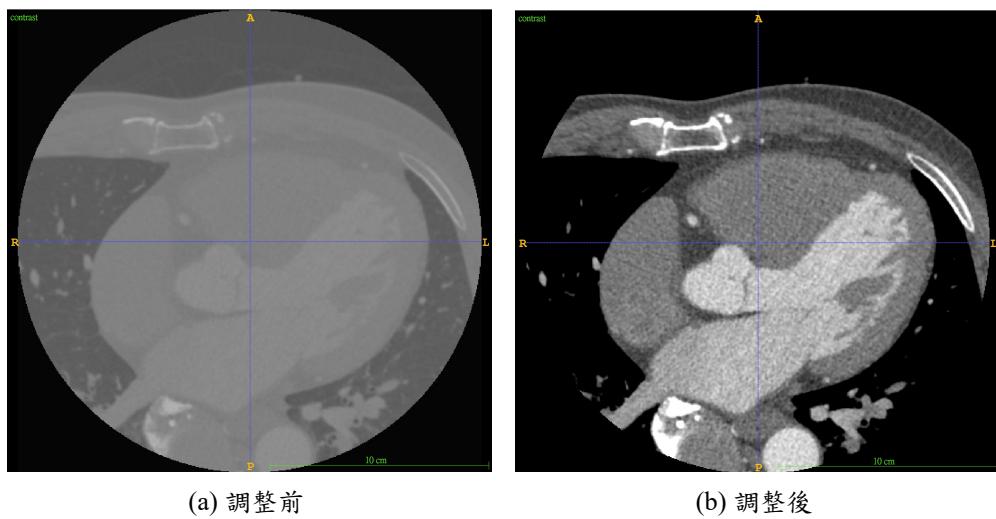


圖 3.2: 有顯影劑增強之電腦斷層影像數值調整

對於無顯影劑增強之電腦斷層影像也依照上述方式，以下界 -300 HU 以及上界 500 HU 進行調整。圖 3.3為調整前後之影像以灰階圖呈現的結果。

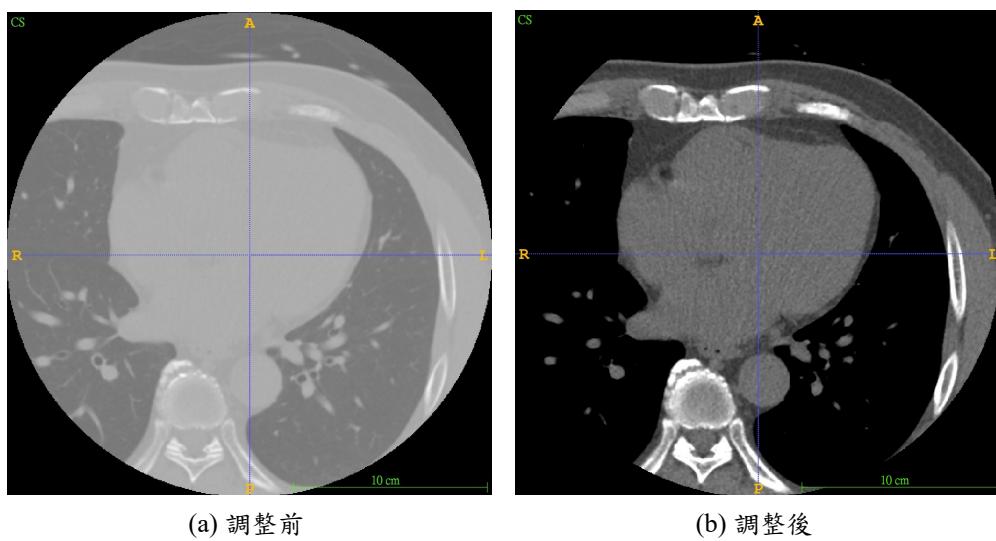


圖 3.3: 無顯影劑增強之電腦斷層影像數值調整

3.1.2 影像壓縮

由於原始影像大小過於龐大，受限於運算資源，無法一次使用完整的 3D 影像進行訓練，因此影像在輸入模型進行訓練、預測前會先進行圖片大小壓縮，並將模型輸出結果以線性內插轉換回原始大小進行評估。表 3.1為原始影像大小以及壓縮後的大小，表 3.1中的數值分別為三維影像之長、寬、高像素數量。

表 3.1: 原始影像大小及壓縮後大小

名稱	原始影像大小	壓縮後大小
有顯影劑增強影像	(512, 512, 256)	(192, 192, 192)
無顯影劑增強影像	(512, 512, 64)	(256, 256, 64)

3.2 無顯影劑影像資料擴增模型

圖 3.4為自同一受檢者拍攝之有、無顯影劑之電腦斷層影像，從資料中可以觀察到無顯影劑增強之電腦斷層影像對於血管對比度較低，在有顯影劑增強之電腦斷層影像，如圖 3.4a 中，心臟血液流經的部分為白色，與其他組織較有差異性；而在無顯影劑增強之電腦斷層影像，如圖 3.4b 中，心臟血液流經的部分則與其他組織較無差異。

此種差異增加了標記資料的難度，使得原本就需要耗費大量時間的人工標記血管任務，在無顯影劑增強的電腦斷層影像中更為困難，且標記之血管結果不如血管對比度較高的有顯影劑增強之電腦斷層影像，使得取得品質優良之標記資料難度也更高。

一個能利用既有資料輔助訓練的想法是，將已標記之有顯影劑增強之電腦斷層掃描影像進行影像風格轉換，將其轉換為無顯影劑增強之電腦斷層掃描影像做為額外的訓練資料。其中 CycleGAN 已被許多研究用於醫學影像之影像風格轉換研究 jiangTumorAwareAdversarialDomain2018, welanderGenerativeAdversarialNetworks2018, songNoncontrastCTLiver2020，

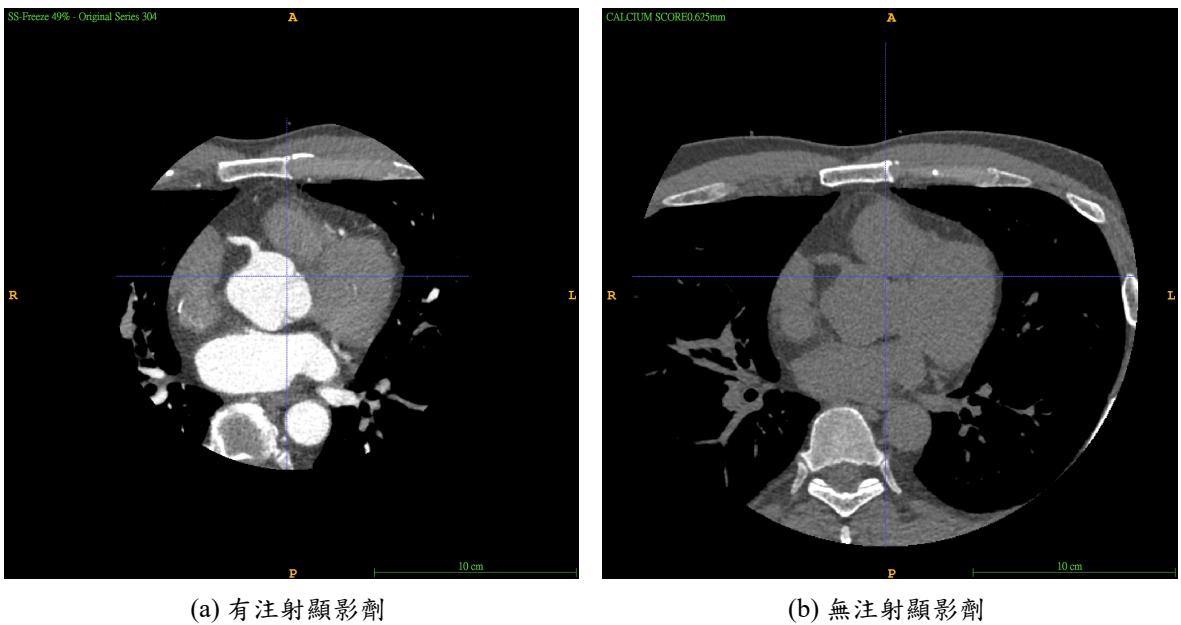


圖 3.4: 有無顯影劑增強之電腦斷層影像

目前也有研究使用深度學習技術進行醫學影像的轉換，並用於資料擴增的任務上 **songNoncontrastCTLiver2020**。

本研究使用 CycleGAN 訓練一個影像風格轉換模型，將有顯影劑增強之電腦斷層影像轉換為虛擬的無顯影劑增強之電腦斷層影像，即是將圖 3.4a 轉換為圖 3.4b，並使用在有顯影劑增強之電腦斷層影像標註之冠狀動脈分割標記，做為無顯影劑增強之電腦斷層影像冠狀動脈分割任務的擴充資料，期望能以現有資料增加分割模型的效果。

有無使用 CycleGAN 對於訓練無顯影劑增強之電腦斷層影像冠狀動脈分割模型的結果，會在實驗設計與結果的章節進行討論。

3.3 冠狀動脈分割

目前已有許多研究 **huangCoronaryArterySegmentation2018**, **chenCoronaryAr** 對於有顯影劑增強之電腦斷層影像進行冠狀動脈分割的任務達成不錯的成果，3D U-Net 是其中被廣泛運用於醫學影像分割的模型，因此本研究使用 3D U-Net 做為冠狀動脈分割任務之模型。

模型訓練所使用的目標函數為骰子損失函數 (Dice Loss)，其函式為

式 (4.1)

$$Loss = 1 - \frac{2|X \cap Y|}{|X| + |Y|} \quad (3.1)$$

其中 X、Y 分別為模型預測結果以及模型預期結果，當兩者重疊部分越多且不重疊部分越少時，損失數值越低，反之則愈高。

雖然有顯影劑增強之電腦斷層影像相較於無顯影劑增強之電腦斷層影像能夠更精確地顯示血管位置，並取得較佳的冠狀動脈分割結果，然而部分對於碘成分過敏或是腎臟功能有問題的受檢者，可能會對顯影劑產生不良反應 **andreucciUpdateRenalToxicity2017**, **rasuliMetforminContrastMedia1998**, **saljoughianIntravenousRadiocontrastMedia2017**。這些受檢者較不適合使用顯影劑，因此本研究也實驗了以無顯影劑增強之電腦斷層影像進行冠狀動脈分割實驗，期望提供不適合注射顯影劑的受檢者初步的冠狀動脈分割，以輔助醫師在後續的診斷流程。

3.4 有顯影劑冠狀動脈分割之相關應用

3.4.1 鈣化位置偵測

目前在進行完整的冠狀動脈疾病風險評估時，會需要同時使用有顯影劑以及無顯影劑增強之影像，分別進行冠狀動脈分割以及鈣化位置偵測，流程如圖 3.5 所示，在進行電腦斷層掃描攝影時，受檢者會先在無注射顯影劑時進行電腦斷層影像攝影，取得無顯影劑增強之電腦斷層影像，接著再接受顯影劑注射，進行第二次電腦斷層影像攝影取得有顯影劑增強之電腦斷層影像。

有顯影劑增強之影像將會利用於標註冠狀動脈結構，使得醫師能夠了解受檢者的冠狀動脈結構、是否有血管狹窄度的情形，無顯影劑增強之影像則會利用於鈣化位置標註，使得醫師能夠了解受檢者的冠狀動脈是否有鈣化以及鈣化的位置，將冠狀動脈結構以及鈣化位置搭配進行參



圖 3.5: 冠狀動脈疾病風險評估流程

考，能夠更精確地了解鈣化在血管中的位置。

然而在這樣的流程下，受檢者會需要接受兩次的電腦斷層影像攝影，接受兩次的輻射暴露，因此本研究希望能直接使用有顯影劑增強之電腦斷層影像進行鈣化位置評估，透過提供醫生輸入欲擷取之 HU 值閾值，利用血管分割模型的結果擷取出血管周遭的鈣化位置並以視覺化呈現，使得受檢者只需進行一次有注射顯影劑之電腦斷層掃描攝影，便能找到其血管中可能有鈣化的位置，降低受到輻射暴露的風險。

本研究的流程如圖 3.6所示，受檢者會在注射顯影劑後進行電腦斷層掃描攝影，透過本研究提出之冠狀動脈分割模型進行自動冠狀動脈分割，並使用冠狀動脈分割結果、原始電腦斷層影像、以及使用者輸入之目標 HU 閎值，透過取三者之交集，將血管位置中超過使用者輸入 HU 閎值之位置視為鈣化位置，並將其以視覺化呈現，提供醫生進行診斷時參考。

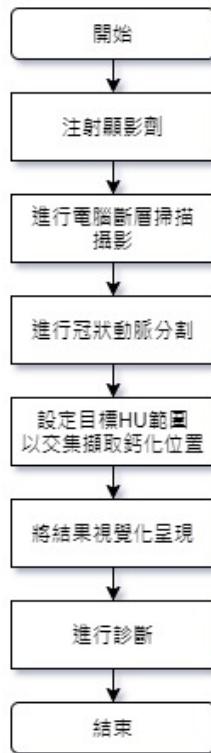


圖 3.6: 僅以有顯影劑資料進行鈣化位置偵測流程

3.4.2 狹窄度分析

在冠狀動脈心臟病的診斷中，血管狹窄度是一個重要的指標，目前醫師可以透過電腦斷層掃描影像或分割之血管結果，了解受檢者之血管管徑趨勢，藉以診斷受檢者是否有血管狹窄的情形。

然而單純以目視的方式難以精準的了解受檢者之血管管徑數據，且冠狀動脈是一個在三維空間中往不同方向發展的結構，在判斷血管管徑時會需要考慮到不同觀察方向，也使得進行診斷時的不便，因此本研究期望能提供醫師於血管狹窄度分析時更方便的資料，藉由冠狀動脈分割結果取得其中心線，將原始影像轉換為以中心線投影之拉直後之影像，使得更容易的看出血管管徑趨勢，此外，本研究也以拉直後之影像計算血管管徑並繪製成趨勢圖，以方便醫師進行對血管狹窄度的分析。

本研究之狹窄度分析流程如圖 3.7所示，首先會透過原始影像中分割出冠狀動脈結構，並將分割結果進行細線化處理取得中心



圖 3.7: 狹窄度分析流程

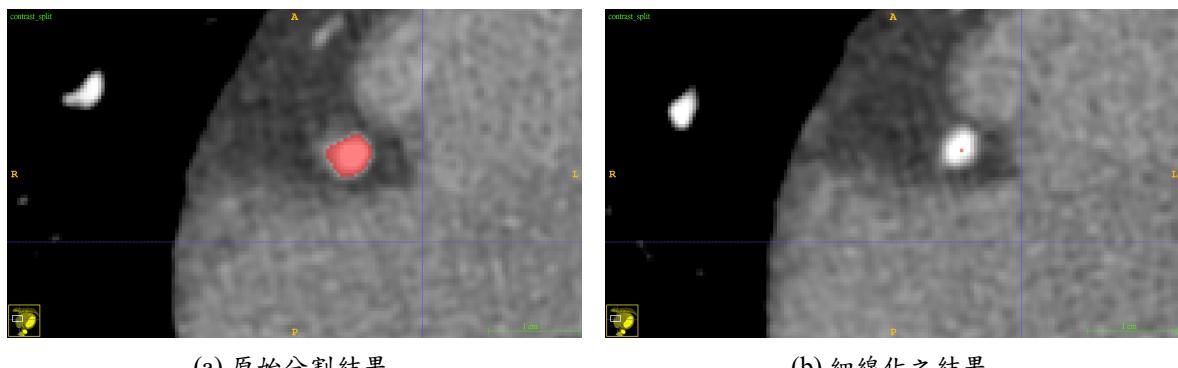


圖 3.8: 細線化處理取得中心線

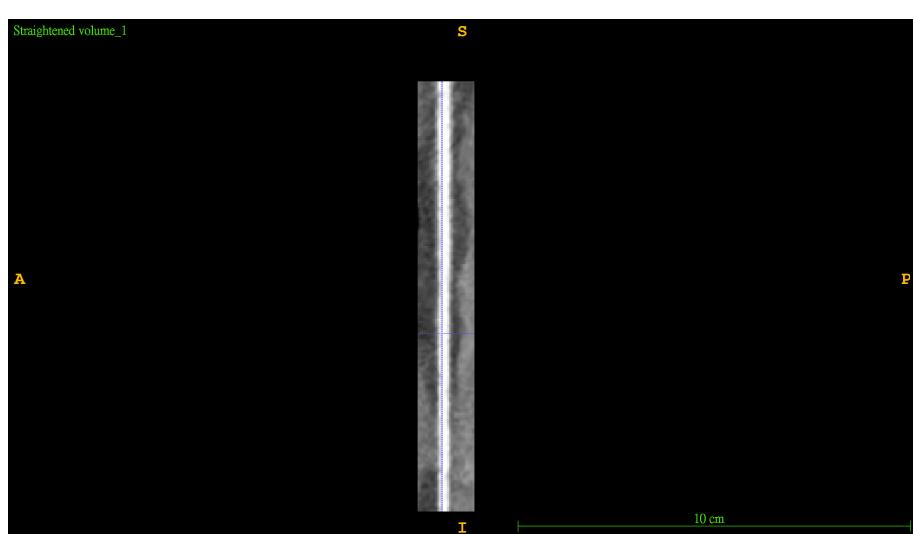


圖 3.9: 以血管中心線拉直之原始影像

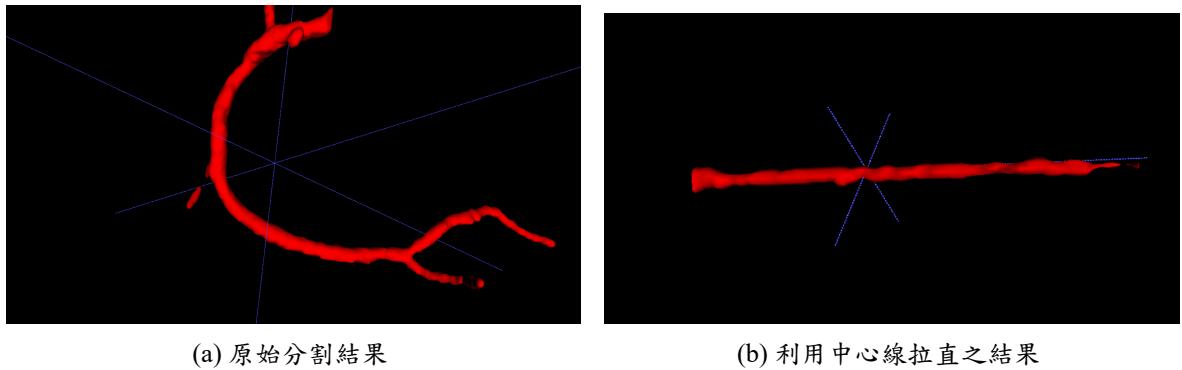


圖 3.10: 以血管中心線拉直之冠狀動脈分割

線，中心線轉換的結果如圖 3.8，圖 3.8 中紅色部分分別為原始分割結果以及細線化得到之中心線，接著利用 Curved Planar Reformation 方法 **kanitsarCPRCurvedPlanar2002** 以血管中心線對原始影像進行座標轉換，為利用血管中心線做為向量，產生以中心線之拉直後之影像，原始影像以 RCA 主支中心線進行轉換的結果如圖 3.9，圖 3.9 之結果會用提供給使用者做為額外的參考資料，圖 3.10 冠狀動脈分割以 RCA 主支中心線進行轉換的結果，本研究會利用轉換後之冠狀動脈分割計算血管管徑，並繪製成趨勢圖，以方便醫師進行對血管狹窄度的分析。

3.4.3 資料視覺化

本研究使用開源軟體 3D Slicer **theslicercommunity3DSlicerImage**, **fedorov3DSlicerImage2012**, **geringIntegratedVisualizationSystem1999**, **geringIntegratedImpactMedical2016**, **kikinis3DSlicerPlatform2014**, **pieperNAMICK** 做為資料視覺化平台，軟體介面如圖 3.11。

3D Slicer 提供多平台的桌面應用程式，能在 Windows, Linux, MacOS 上運行，並且支援多種格式的醫學影像資料、資料檢視方式以及資料處理工具，此外，使用者能夠利用 Python 撰寫自定義的 3D Slicer 套件，使得使用者能在 3D Slicer 中呼叫自行撰寫的 Python 程式、深度學習模型進行資料處理，並將結果回傳至 3D Slicer 進行呈現。

本研究將冠狀動脈分割模型、鈣化位置分析模組、狹窄度分析模組

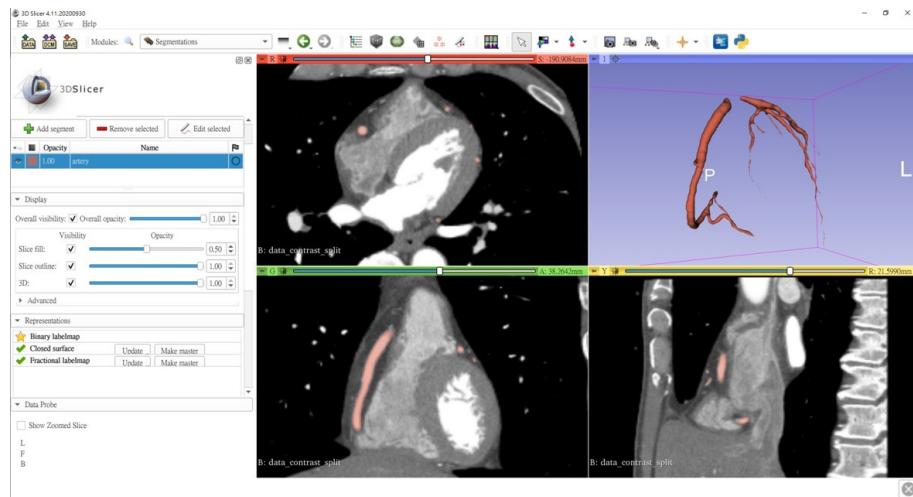


圖 3.11: 3D Slicer 軟體介面

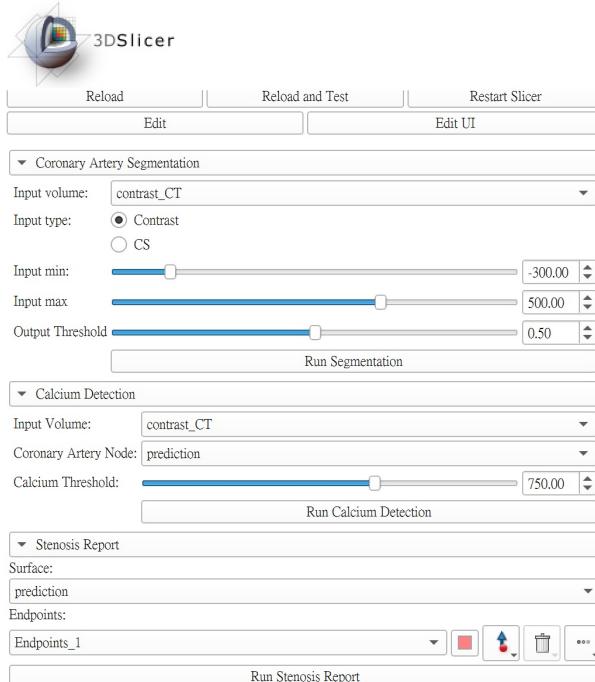


圖 3.12: 3D Slicer 自定義套件

以 3D Slicer 套件的形式整合至 3D Slicer 中，套件介面如圖 3.12，使用者可以將心臟電腦斷層影像匯入至 3D Slicer，選取來源影像、是否有顯影劑以及 HU 範圍呼叫深度學習模型進行冠狀動脈自動標記。對於有顯影劑影像所擷取出之冠狀動脈，可以設定 HU 閻值呼叫鈣化位置分析模組進行鈣化位置偵測，此外，使用者能夠選取血管的兩端點呼叫狹窄度分析模組，取得以中心線拉直後血管影像以及血管管徑趨勢圖。

四、 實驗設計與結果

4.1 資料集

本研究使用為合作醫院所提供之資料集，為心臟範圍之電腦斷層掃描影像，電腦斷層掃描設備輸出之原始影像數值為 HU 值。資料集分別有三大類資料：

1. 已標記之有顯影劑增強影像，共 21 組，每一組影像為 256 張，大小為 512×512 ，其針對冠狀動脈血管分成四類進行標記，分別為 RCA、LM、LAD、LCx。運用於訓練以有顯影劑增強電腦斷層影像進行冠狀動脈分割之模型，以及利用風格轉換模型產生虛擬的無顯影劑增強電腦斷層掃描影像，做為無顯影劑增強冠狀動脈分割模型的擴增資料。
2. 已標記之無顯影劑增強影像，共 10 組，每一組影像為 64 張，大小為 512×512 ，其將所有冠狀動脈視為一類進行標記，運用於訓練對無顯影劑增強電腦斷層影像進行冠狀動脈分割之模型。
3. 未標記之同一個案之有顯影劑增強影像與無顯影劑增強影像，共 45 組，其中 28 組影像為 2×256 張、16 組影像為 2×224 張、1 組影像為 2×192 張，大小皆為 512×512 ，運用於訓練將有顯影劑增強影像轉換為無顯影劑增強影像之模型。

4.2 有顯影劑增強影像之冠狀動脈分割

本研究利用 21 組已標註冠狀動脈的有顯影劑增強之電腦斷層影像，訓練以有顯影劑增強之電腦斷層影像進行冠狀動脈分割之 3D U-Net 模型，由於實驗樣本數較少，以 K-fold 交叉驗證方式進行實驗，其中 18 組做為訓練資料，3 組做為測試資料，總共分為 7 個 Fold 進行實驗。

模型輸入為前處理後的三維影像，訓練資料如圖 4.1 所示，其中圖 4.1a 為電腦斷層掃描單切的影像，每一組壓縮後的資料一共會有 192 切影像，並可以藉由堆疊組成三維的影像，以透過不同方向如圖 4.1b 以及圖 4.1c 來進行觀察。圖 4.1a、圖 4.1b、圖 4.1c 中有顏色部分為人工標記的冠狀動脈位置，淺藍色為 RCA、綠色為 LM、深藍色為 LCx、黃色為 LAD，為 3D U-Net 之預期輸出，圖 4.1d 為冠狀動脈標記以之三維影像呈現的結果。

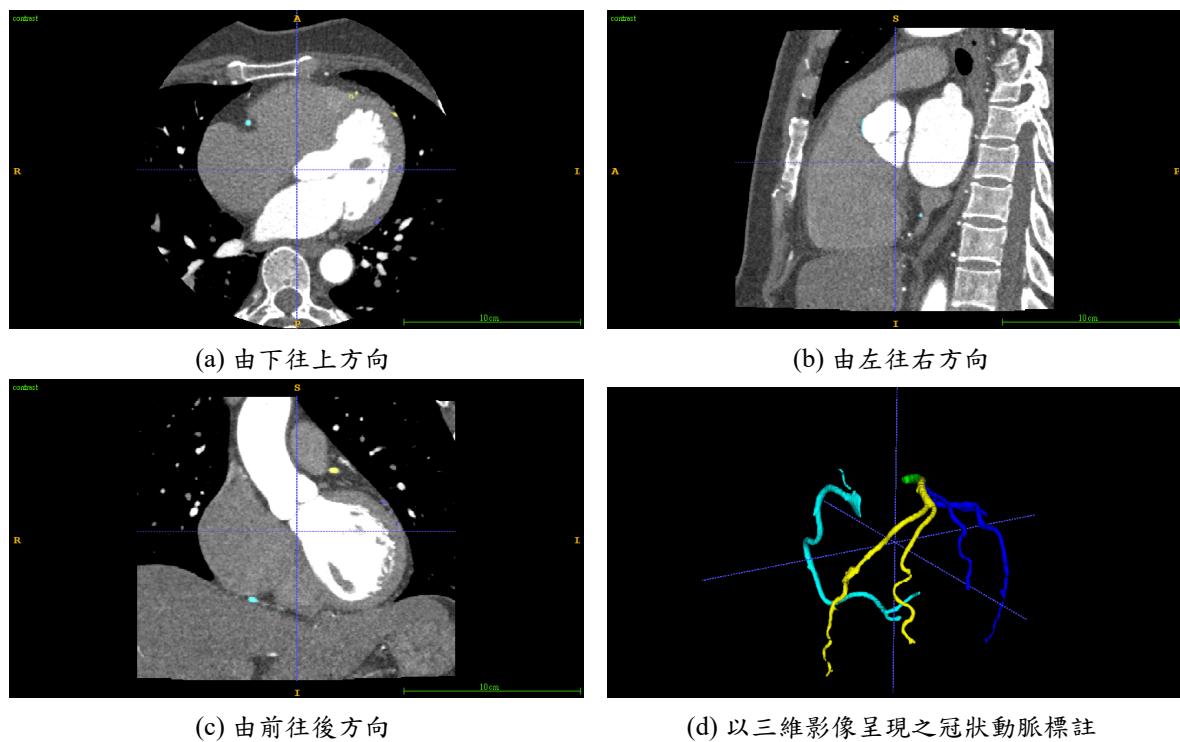


圖 4.1: 模型訓練資料範例-有顯影劑增強

模型訓練所使用目標函數為骰子損失函數 (Dice Loss)，函式為

式 (4.1)，各分類冠狀動脈將分別計算各分類的目標函數。

$$Loss = 1 - \frac{2|X \cap Y|}{|X| + |Y|} \quad (4.1)$$

模型結果以骰子係數 (Dice Coefficient) 進行評估，其函式為式 (4.2)，骰子係數之值愈高，則代表模型分割結果與人工標記結果重合部分越多，反之則愈少。

$$DiceCoefficient = \frac{2|X \cap Y|}{|X| + |Y|} \quad (4.2)$$

訓練完成的模型以 7-Fold 交叉驗證對於測試資料集之結果如表 4.1，表 4.1列出各類血管分類的 Dice Coefficient，以及將所有血管視為一類的 Dice Coefficient 結果。

表 4.1: 有顯影劑增強之電腦斷層掃描 7-Fold 交叉驗證結果

Fold	Dice Coefficient				
	All	RCA	LM	LAD	LCx
1	0.7942	0.7918	0.7156	0.6868	0.7559
2	0.7674	0.7934	0.4106	0.6718	0.5660
3	0.7941	0.7838	0.7214	0.6642	0.6066
4	0.7859	0.7954	0.6040	0.7237	0.7064
5	0.7650	0.6837	0.6911	0.6811	0.7169
6	0.7644	0.7806	0.5654	0.6077	0.6233
7	0.8368	0.8248	0.7608	0.7984	0.7414
Average	0.7868	0.7791	0.6384	0.6905	0.6738

結果顯示，本研究所實驗之 3D U-Net 模型對於測試資料集，以全部冠狀動脈分割在 7-Fold 交叉驗證中平均能達到 Dice Coefficient 0.7868 的結果，影響結果 Dice Coefficient 的狀況有分割錯誤以及分類錯誤，分割錯誤為未分割出標記中所包含的血管或是分割出的結果不在標記中，圖 4.2為一個分割錯誤的範例，可以看到圖 4.2b之模型分割結果較圖 4.2a之人工標記缺少一些部分，而分類錯誤則是分割出之結果是冠狀動脈，但血管分類並不正確，圖 4.3a為一個分類錯誤的範例，部分分類錯誤的情形也導致表 4.1個別血管的結果會較整體血管的 Dice Coefficient

來的低，血管分類中表現較好者為 RCA，由於 RCA 與 LM、LAD、LCx 位置距離較遠，推測是其在分割與分類上結果較好的原因，血管分類中較差且不同實驗差異較大的為 LM，推測原因為 LM 本身體積較小且 LM 又會分支為 LAD、LCx，因此在分支交界處常發生分類錯誤的情形，而由於其體積較小，當分類錯誤發生時會較大幅度地影響其結果之 Dice Coefficient。

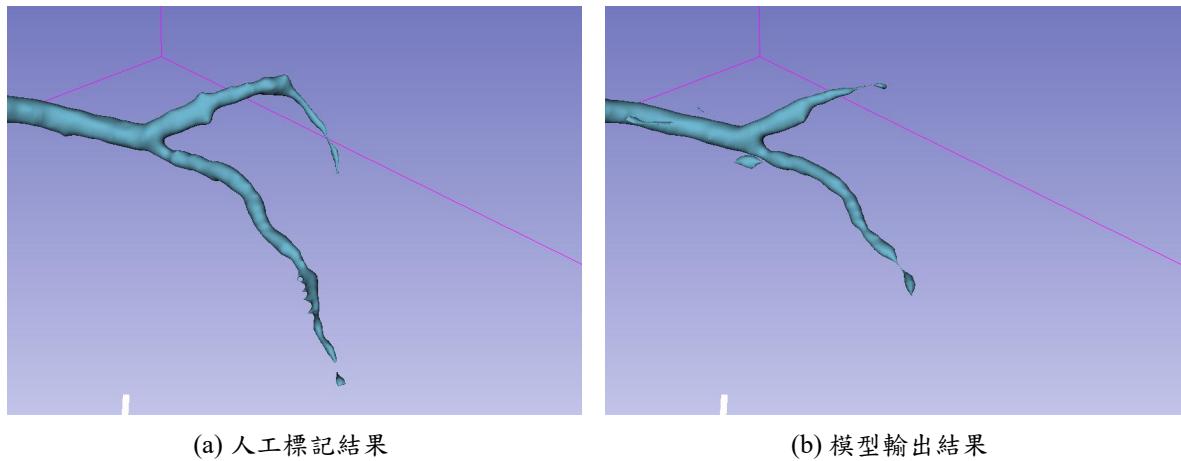


圖 4.2: 模型分割錯誤範例

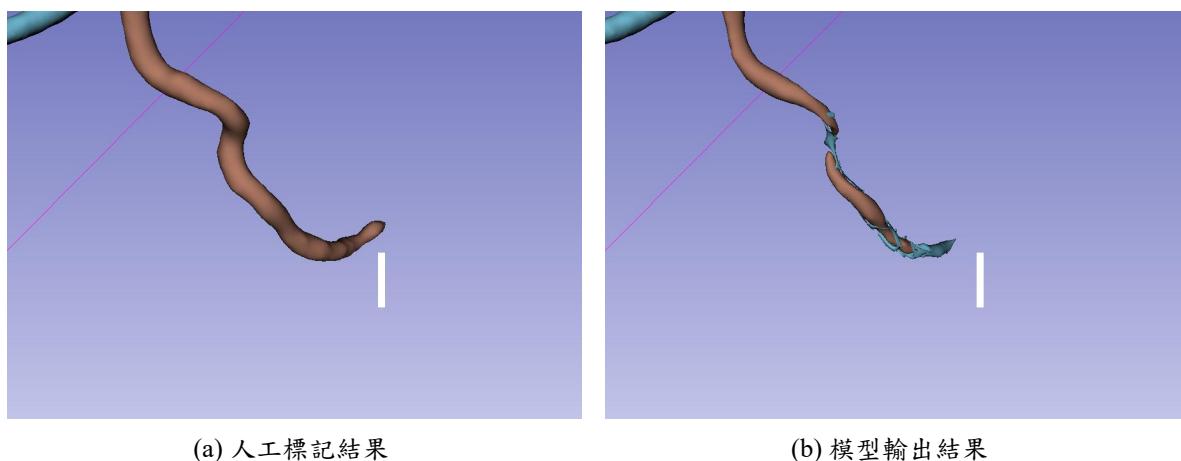


圖 4.3: 模型分類錯誤範例

與其他相關研究的結果比較如表 4.2，以 Dice Coefficient 數值來說，本研究相較於 Moeskops 等人 **moeskopsDeepLearningMultitask2016** 與 Huang 等人 **huangCoronaryArterySegmentation2018** 之結果較好，但是並不如 Chen 等人 **chenCoronaryArterySegmentation2019** 之結果，此部分會

因為本研究使用的資料為合作醫院所提供之資料，與其他研究的結果直接進行比較會有一些偏差，不一定為絕對的較好或較差，然而本研究沒有使用額外的前處理資料如 Huang 等人 **huangCoronaryArterySegmentation2018** 所使用的中心線以及 Chen 等人 **chenCoronaryArterySegmentation2019** 所使用的血管增強處理方法，卻能達到相近甚至較好的結果，這部分認為是因為本研究沒有將原始資料以 Patch 的方式切割，而是將影像壓縮至 $192*192*192$ 大小以完整影像進行訓練的原因，因此在不進行後處理的情況下，本研究的冠狀動脈結果能有較少的雜訊。

表 4.2: 有顯影劑增強之電腦斷層掃描分割結果與其他研究比較

本研究	Moeskops 等人 moeskopsDeepLearningMultitask2016	Huang 等人 huangCoronaryArter
0.7868	0.65	0.7755

圖 4.4為一模型較佳之輸出結果範例，可以觀察到在輸出結果中冠狀動脈大致皆有被正確的分割與分類，然而在較末端與較小的血管尚有一些分割錯誤，如圖 4.4a 中人工標記之藍色與中黃色之部分血管在圖 4.4b 中模型輸出結果中並未被正確分割出來，然而模型也有額外分割出人工標記中未標記到的部分，如圖 4.4b 中棕色的最下方，顯示模型對於冠狀動脈分割的能力有一定的推廣性。

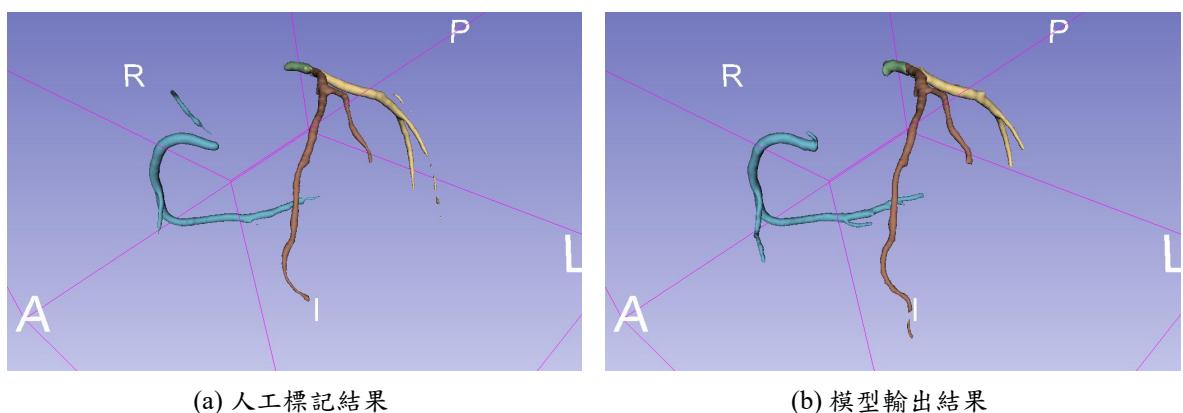


圖 4.4: 有顯影劑增強之電腦斷層掃描分割較佳結果範例

圖 4.5為一模型較差之輸出結果範例，可以觀察到在輸出結果中冠狀動脈大致皆有被正確的分割與分類，然而此範例有較多之分割錯誤，如

圖 4.5b 中多出之藍色以及棕色分割，以及棕色與黃色部分有較多未分割出來的狀況，此外也有一些分類錯誤的情形，不過整體仍然能正確的分割出大部分的冠狀動脈。

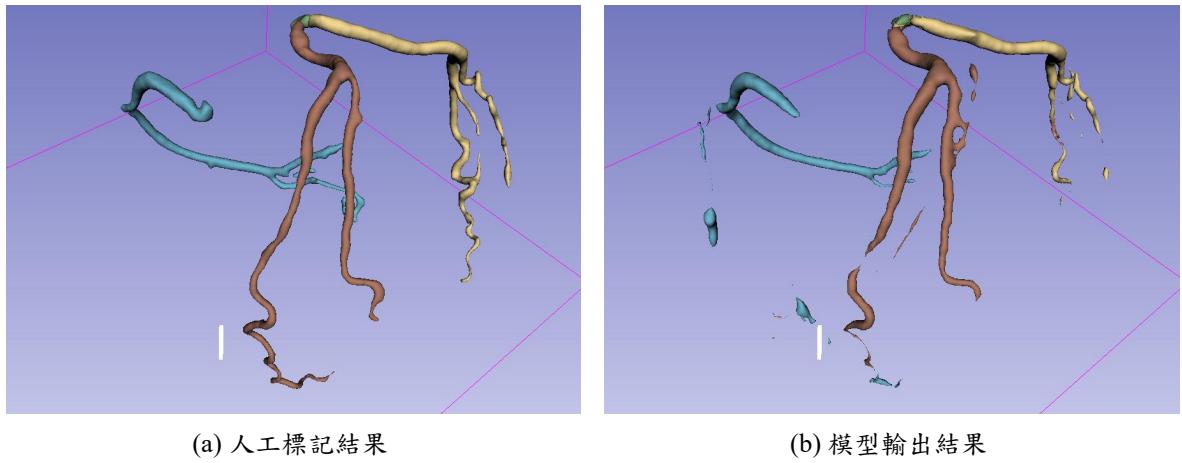


圖 4.5: 有顯影劑增強之電腦斷層掃描分割較差結果範例

4.3 電腦斷層掃描影像風格轉換

本研究利用 45 組擁有無注射顯影劑以及有注射顯影劑的受檢者資料，訓練將電腦斷層影像由有顯影劑增強轉換為無顯影劑增強之 CycleGAN 模型，模型輸入資料為單張 2D 電腦斷層掃描影像，包含有顯影劑增強以及無顯影劑增強之影像，總計共有 10944 張 2D 電腦斷層影像，其中 9792 張做為訓練資料、1152 張做為測試資料。

訓練結果最好的 CycleGAN 模型對於測試資料結果如圖 4.6，圖 4.6 中最左邊為 CycleGAN 輸入之原始有顯影劑增強之電腦斷層影像，中間為 CycleGAN 轉換後的虛擬無顯影劑增強電腦斷層影像，右邊為同一受檢者於相同位置的真實無顯影劑增強電腦斷層影像。

於圖 4.6可以看到 CycleGAN 能夠確實地將有顯影劑增強之電腦斷層影像中亮度較高之含有顯影劑的血液流經處進行調整，產生如真實無顯影劑增強電腦斷層影像的結果，這邊需要注意的是，雖然圖 4.6 中，每一列有顯影劑增強與無顯影劑增強之電腦斷層影像來自於同一個案，但由

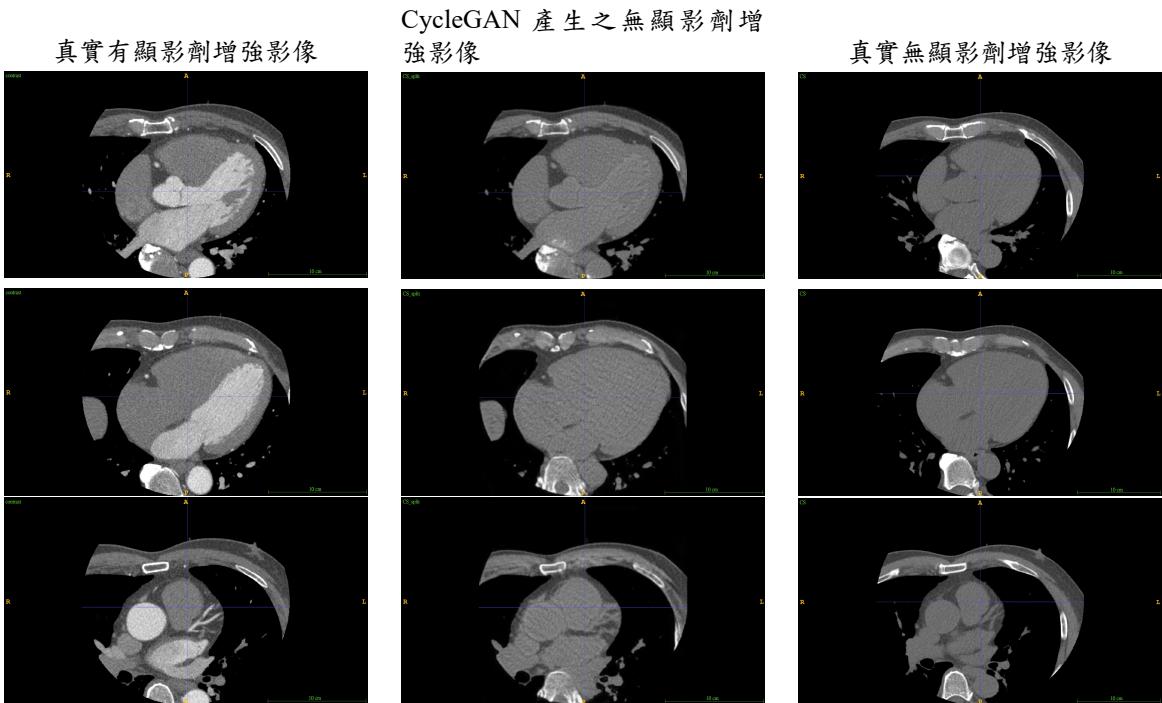


圖 4.6: 原始影像與 CycleGAN 轉換結果範例

於是不同時間進行的電腦斷層掃描攝影，因此影像中兩者心臟組織結構無法完全重合。

本研究利用訓練完成之 CycleGAN 模型將已標記之有顯影劑增強電腦斷層影像進行轉換，產生虛擬的無顯影劑增強電腦斷層影像資料，並在無顯影劑增強電腦斷層影像冠狀動脈分割實驗中做為擴增資料集，以評估資料擴增方法是否能有效提升模型效果。

4.4 無顯影劑增強影像之冠狀動脈分割

本研究利用 10 組已標註冠狀動脈的無顯影劑增強之電腦斷層影像，訓練已有顯影劑增強之電腦斷層影像進行冠狀動脈分割之 3D U-Net 模型，由於實驗樣本數較少，本研究以 K-fold 交叉驗證方式進行實驗，其中 8 組做為訓練資料，2 組做為測試資料，總共分為 5 個 Fold 進行實驗。圖 4.7為訓練資料範例，此外，本實驗利用 CycleGAN 將 7 組有顯影劑增強之電腦斷層影像轉換為虛擬的無顯影劑增強電腦斷層影像，做為額外

的資料加入訓練，並比較有無使用 CycleGAN 進行資料擴增對於模型效果的影響。

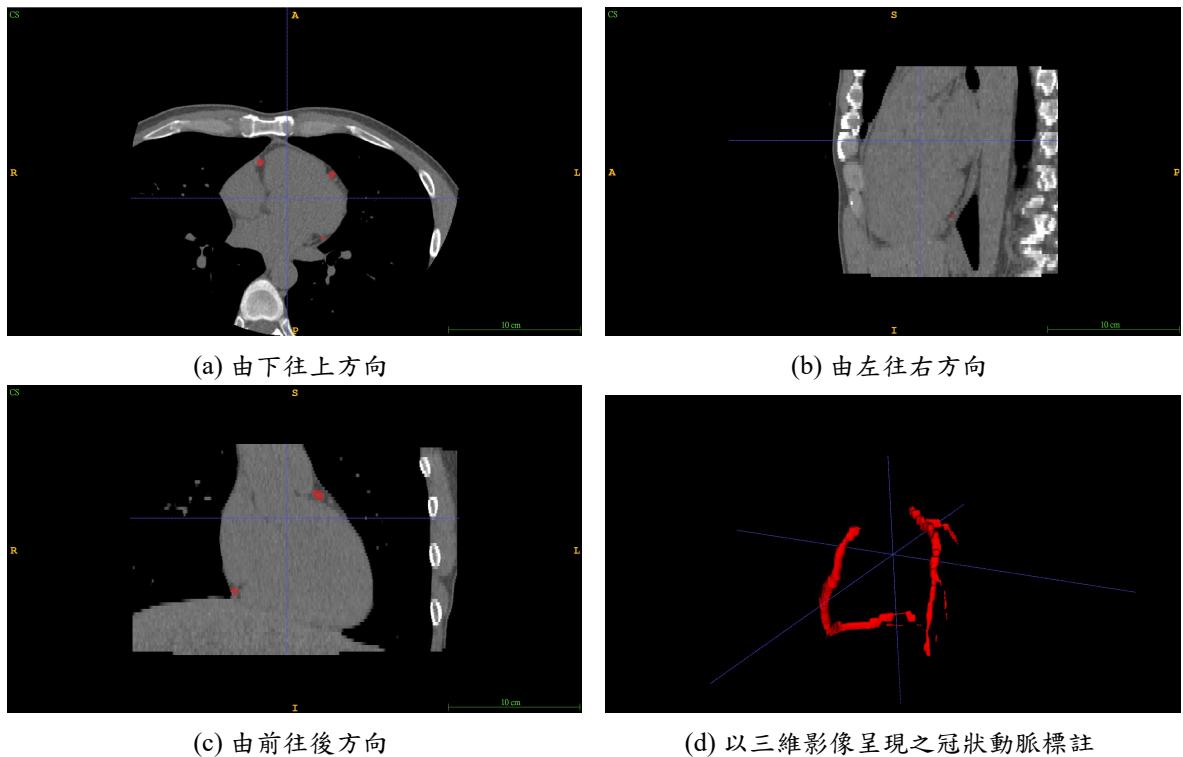


圖 4.7: 模型訓練資料範例-無顯影劑增強

表 4.3為僅使用無顯影劑之原始資料進行訓練之模型結果，對於測試資料集平均可以達到 Dice Coefficient 0.5158 的結果，表 4.4為透過 CycleGAN 將有顯影劑增強之電腦斷層影像資料轉換為虛擬無顯影劑影像，並且做為擴充訓練資料加入訓練之結果，如表 4.4所示，對於測試資料集平均可以提升至 Dice Coefficient 0.5674，圖 4.8為一僅使用原始資料訓練之模型以及加上 CycleGAN 資料擴增之模型的結果範例，可以看到圖 4.8c 中使用 CycleGAN 進行資料擴增之模型能夠分割出更多冠狀動脈結果，顯示本研究之 CycleGAN 資料擴增方法能夠有效的輔助模型訓練並提升分割效果。

雖然 CycleGAN 資料擴增方法能夠有效的輔助模型訓練並提升分割效果，但還是與有顯影劑影像的分割結果有所差距，本研究認為原因包含 1. 無顯影劑影像的低對比度性質，由於沒有顯影劑的幫助，無顯影劑

表 4.3: 無顯影劑增強之電腦斷層掃描分割結果-僅使用原始資料

Fold	Dice Coefficient
1	0.5396
2	0.5164
3	0.5017
4	0.5373
5	0.4842
Average	0.5158

表 4.4: 無顯影劑增強之電腦斷層掃描分割結果-使用 CycleGAN 進行資料擴增

Fold	Dice Coefficient
1	0.6155
2	0.5345
3	0.5330
4	0.6251
5	0.5287
Average	0.5674

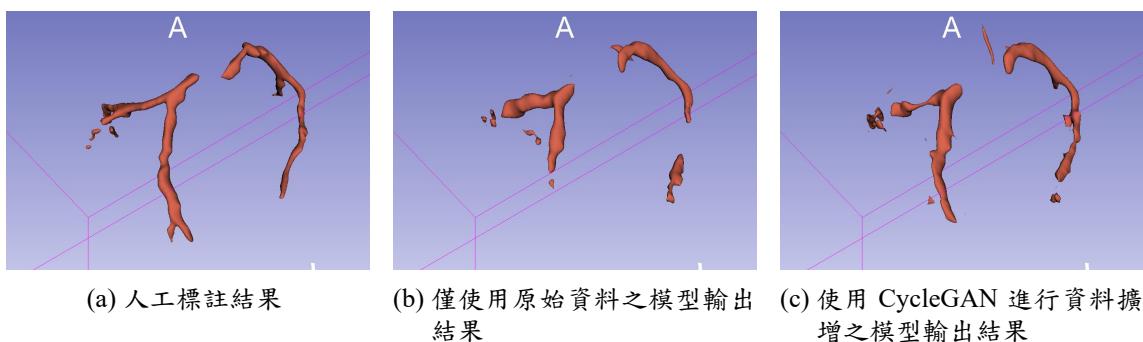


圖 4.8: 有無使用 CycleGAN 進行資料擴增之模型輸出結果

影像中的血管與其他軟組織的對比度較不明顯，因此其分割難度也較有顯影劑影像高許多，2. 本研究使用的無顯影劑影像為 64 切，比起 256 切的有顯影劑影像之解析度較低，因此在分割結果上較難達到良好的連續性。

圖 4.9 以及圖 4.10 為模型較佳之輸出結果範例，可以觀察到在輸出結果中 RCA、LAD、LCx 的主要結構皆有被分割出來，模型對於 RCA 能夠完整地將血管分割出來，然而 LAD 與 LCx 的末端則有較多沒有正確分割出來的結果，也是模型結果較差的主要原因。

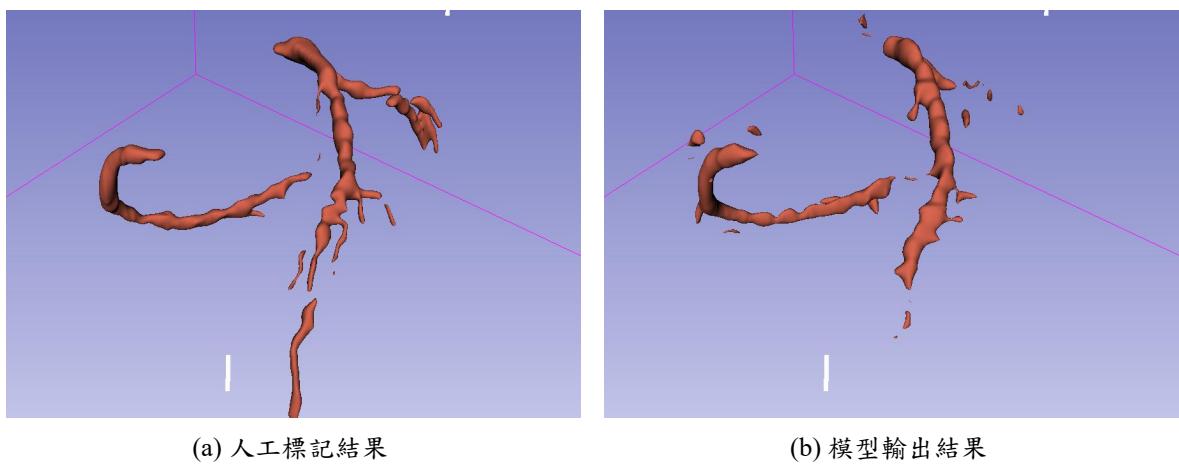


圖 4.9: 無顯影劑增強之電腦斷層掃描分割較佳結果-範例 1

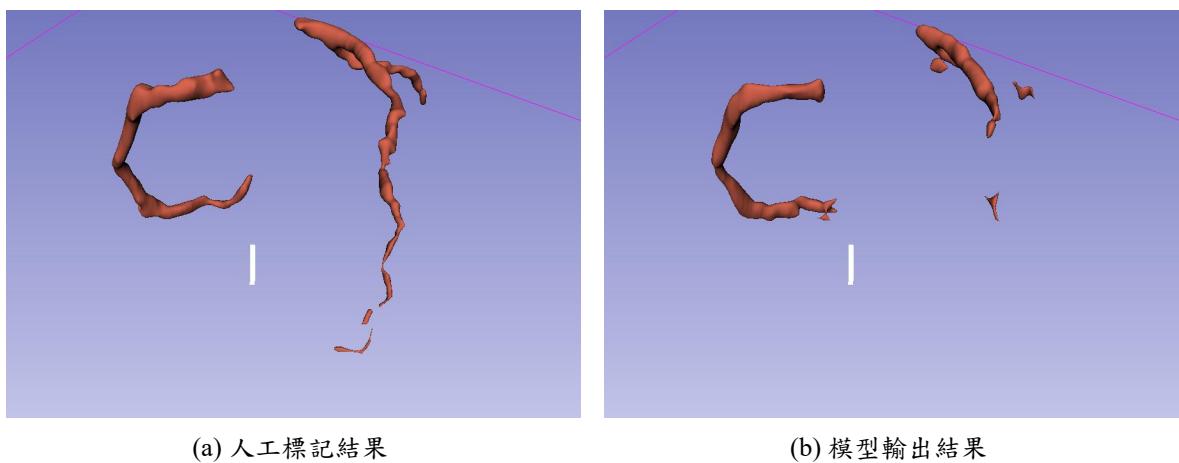


圖 4.10: 無顯影劑增強之電腦斷層掃描分割較佳結果-範例 2

圖 4.11為一模型較差之輸出結果範例，可以觀察到在輸出結果中 RCA、LAD、LCx 的主要結構皆有被分割出來，然而 RCA 末端有一段未被分割出來的血管，且在 LAD 與 LCx 有較多的錯誤分割結果，一些非冠狀動脈的部分也被錯誤地分割出來。

雖然無顯影劑之冠狀動脈分割結果相較於有顯影劑之結果有一些差距，不過顯影劑之冠狀動脈分割模型還是能分割出大致的冠狀動脈結構如 RCA、LAD、LCx 的主要分支，對於不適合注射顯影劑而只能取得無顯影劑電腦斷層影像的受檢者，本研究之無顯影劑冠狀動脈分割模型能夠增強無顯影劑影像的利用價值，做為額外參考資訊提供給醫師，使得在診斷時可以更了解受檢者之冠狀動脈結構。

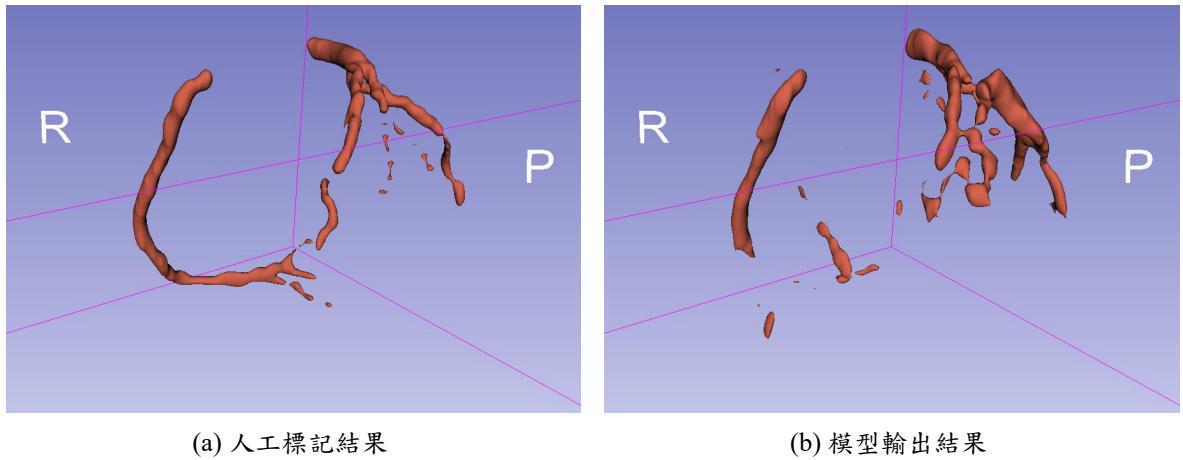


圖 4.11: 無顯影劑增強之電腦斷層掃描分割較差結果範例

4.5 相關應用及視覺化

本研究利用 3D Slicer 做為資料視覺化平台，並將冠狀動脈分割模型、鈣化位置偵測模組以及狹窄度分析模組以 3D Slicer 套件的形式進行實作，因此使用者能夠在 3D Slicer 的強大功能上，使用本研究訓練完成之 3D U-Net 模型進行冠狀動脈分割、鈣化位置偵測與狹窄度分析。

4.5.1 取得血管分析結果

使用者可以使用 3D Slicer 輸入原始影像，並呼叫本研究開發之套件，將原始影像以冠狀動脈分割模型進行預測，並將分割結果輸出至 3D Slicer 進行視覺化。

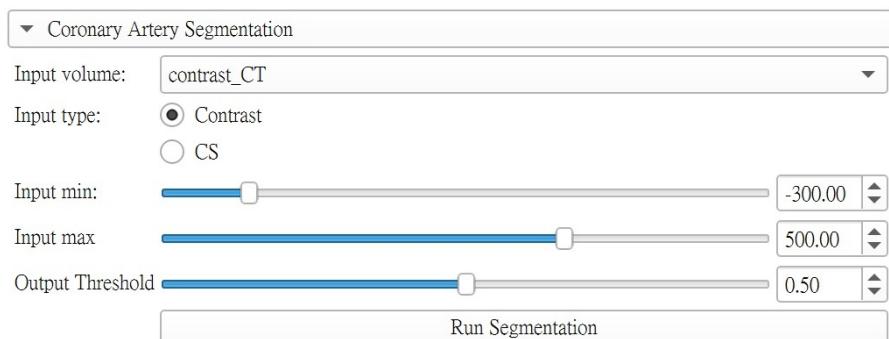


圖 4.12: 本研究開發之套件介面-冠狀動脈分割

套件中的冠狀動脈分割功能之介面如圖 4.12，使用者將原始電腦斷層影像輸入 3D Slicer 後，可以在套件中選取輸入之影像，並且設定輸入影像為有顯影劑增強或是無顯影增強，套件將會依照影像種類選擇不同的深度學習模型進行冠狀動脈分割，另外使用者可以根據原始影像狀況，設定輸入影像欲調整至的之 HU 值上下界，並利用輸出的閥值控制輸出結果，閥值愈低則分隔結果將較多，點選執行後之結果如圖 4.13，右上角為模型分割出之冠狀動脈以 3D 方式呈現之結果。

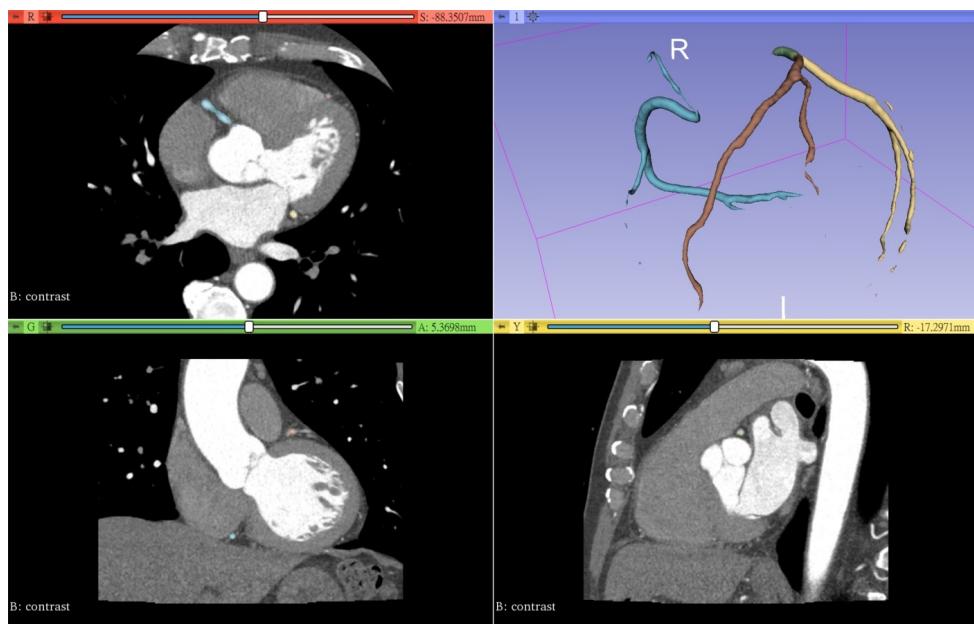


圖 4.13: 3D Slicer 冠狀動脈分割結果視覺化

4.5.2 鈣化位置分析

使用者可以設定 HU 值閥值以有顯影劑增強的影像進行鈣化位置分析，套件會依照冠狀動脈分割結果、使用者指定的 HU 閥值、原始影像進行比對，將冠狀動脈分割結果中，高於指定 HU 閥值判斷為鈣化位置，並繪製成 3D 的視覺化影像，使得醫師能夠初步了解鈣化大約在冠狀動脈的哪個位置。

套件中的鈣化位置分析功能之介面如圖 4.14，使用者在以冠狀動脈分割功能得到冠狀動脈分割結果後，可以在鈣化分析功能選取來源影像、

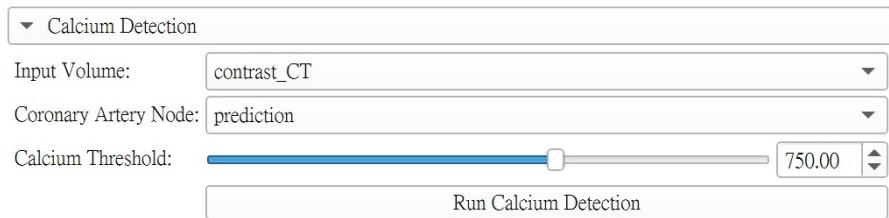


圖 4.14: 本研究開發之套件介面-鈣化位置分析

分割結果並設定欲偵測的鈣化 HU 值，點選執行後之結果如圖 4.15，右上方的血管影像中，白色區域即為依照使用者設定所擷取出的鈣化位置。

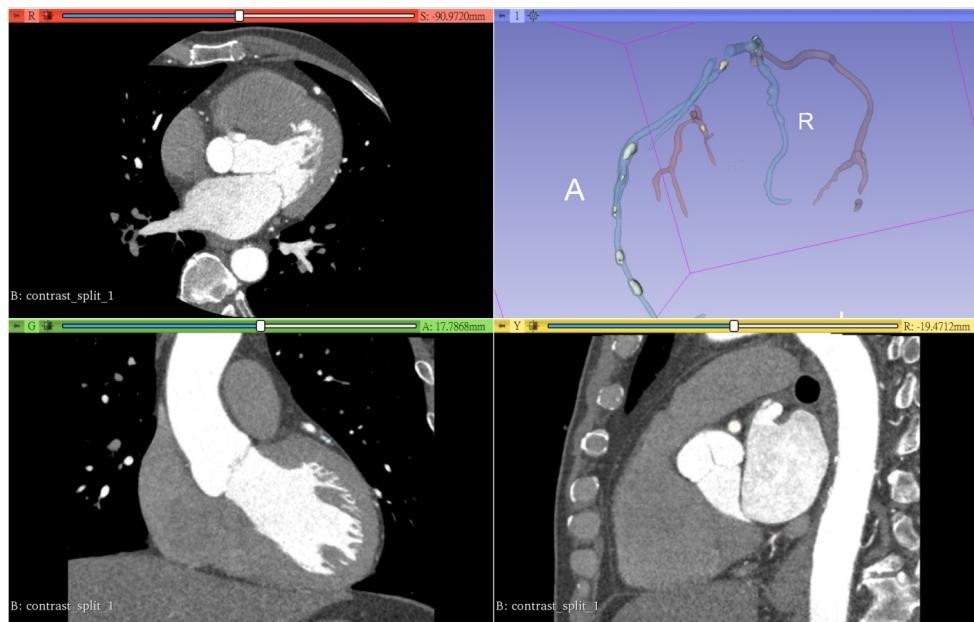


圖 4.15: 3D Slicer 鈣化位置視覺化

4.5.3 狹窄度分析

本研究開發之套件整合了 3D Slicer 之 Extract Centerline 以及 Curved Planar Reformat 套件，使用者可以選取欲分析的血管開始以及結束位置，本套件會利用 Extract Centerline 套件進行血管中心線擷取，並利用 Curved Planar Reformat 產生以中心線拉直的血管 3D 圖。

套件中的狹窄度分析功能之介面如圖 4.16，使用者在以冠狀動脈分割功能得到冠狀動脈分割結果後，可以選取分割結果，並設定血管開始

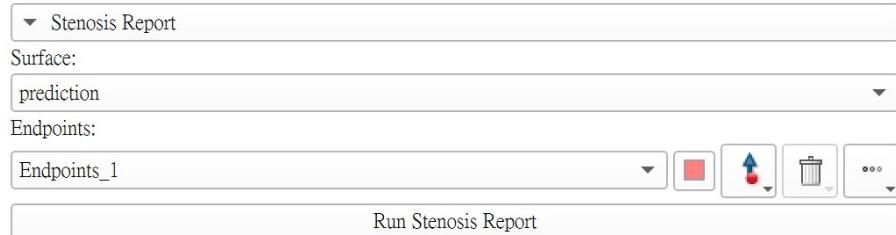


圖 4.16: 本研究開發之套件介面-狹窄度分析

與結束位置，點選執行後之結果可以得到以中心線拉直的血管 3D 圖，如圖 4.17，此外，本研究的套件會依照血管分割結果計算並產生血管管

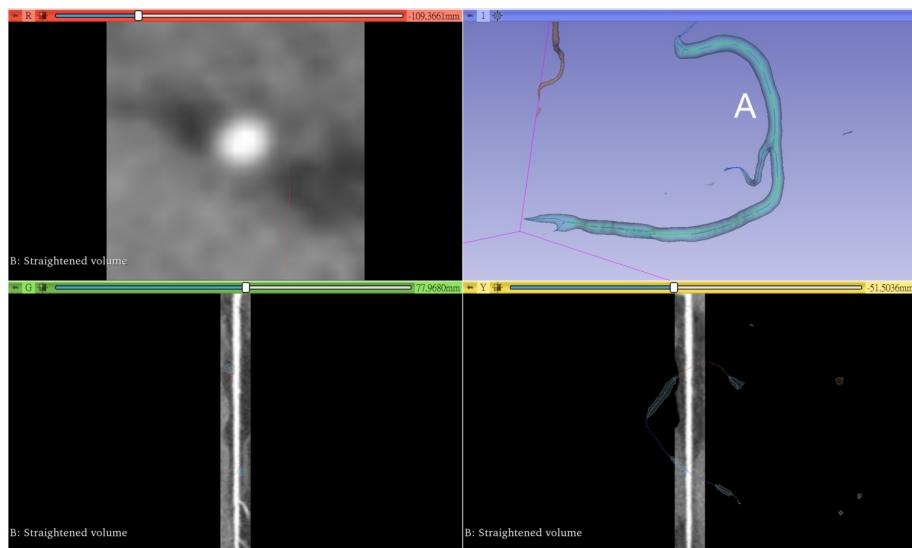


圖 4.17: 冠狀動脈以中心線重組

徑趨勢圖，如圖 4.18為某一受檢者的血管管徑趨勢圖，醫師可以參考該圖片的血管管徑趨勢，輔助評估是否可能有血管狹窄的問題發生。

本研究也利用無顯影劑資料中的分割結果較佳的 RCA 產生拉直之血管 3D 圖，其結果如圖 4.19，顯示無顯影劑冠狀動脈分割模型所分割出的 RCA 也能以狹窄度分析功能獲得更進一步的利用，增強了無顯影劑影像的利用價值。

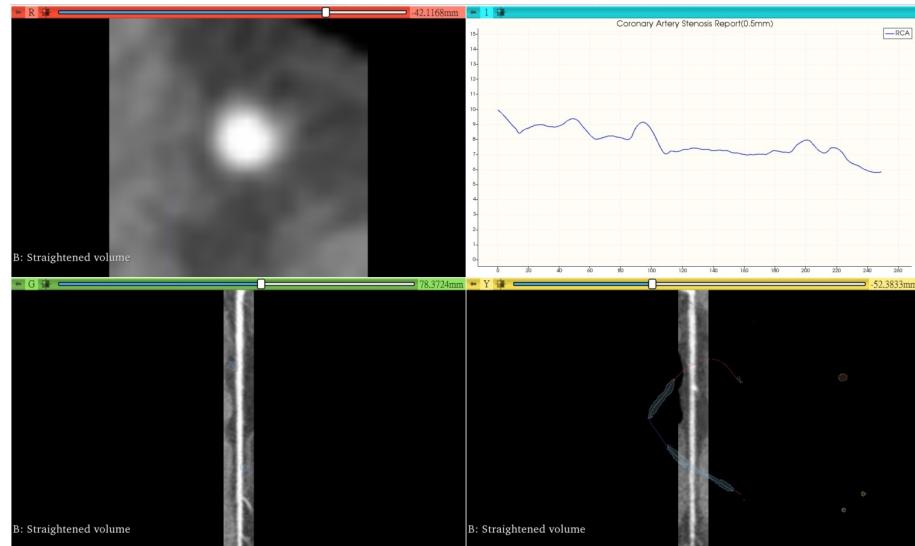


圖 4.18: 冠狀動脈血管管徑趨勢

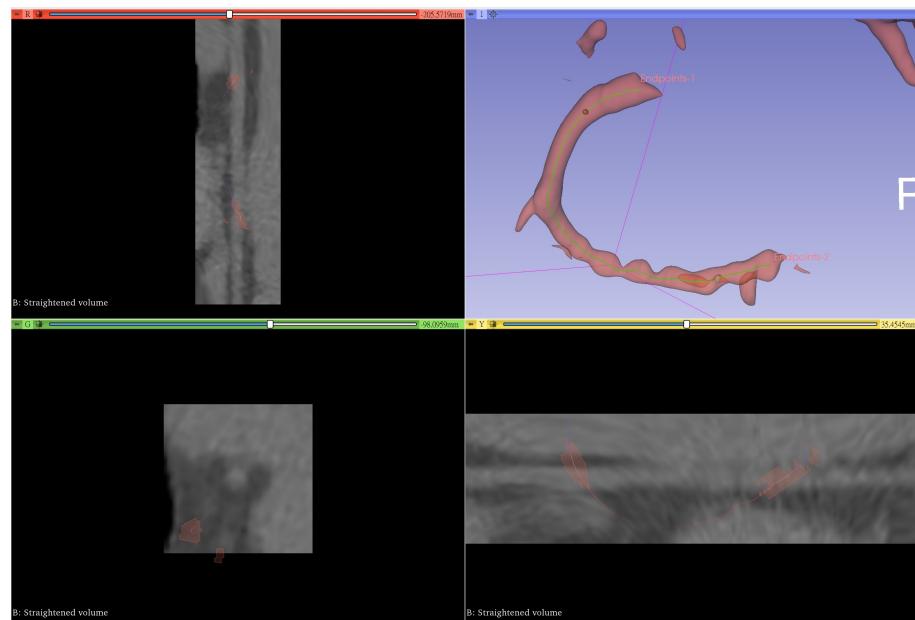


圖 4.19: 無顯影劑影像分割之 RCA 以中心線重組

五、總結

5.1 結論

本研究分別利用了有顯影劑增強以及無顯影劑增強之電腦斷層影像進行冠狀動脈分割實驗，結果顯示，在有顯影劑增強之電腦斷層影像中，深度學習模型已能十分有效的將冠狀動脈分割任務完成，並且能夠提供良好的分割結果以進行相關應用。

對於無顯影劑增強影像之冠狀動脈分割任務，深度學習模型對於冠狀動脈分割也能達到一個初步的成果，取得大致的冠狀動脈主要分布，對於醫師在缺少有顯影劑增強的資料，如受檢者因為身體因素無法接受顯影劑注射時，能夠做為額外的輔助診斷資訊。

本研究將既有的已標記之有顯影劑增強影像，以 CycleGAN 進行影像的風格轉換，產生虛擬的無顯影劑增強影像，做為無顯影劑增強影像冠狀動脈分割任務的額外訓練資料，並且有效地輔助無顯影劑增強資料進行訓練，使得模型結果有所提升。

最後本研究也以有顯影劑增強之影像所分割出的冠狀動脈結果，以 3D Slicer 插件的形式，實作鈣化位置偵測以及狹窄度分析的應用，提升了有顯影劑增強影像及其冠狀動脈分割結果在應用上的價值。

5.2 未來展望

本研究尚有一些能夠改進的部分，期望能在未來繼續研究進行改善與加強。

在冠狀動脈分割模型的部分，目前對於無顯影劑資料進行分割的結果尚還不如有顯影劑的資料，且目前的訓練資料數量還是不足以提供很好的多樣性，導致對於不同的樣本模型效果差異較大，此外本研究在模型及資料前處理的部分也較為簡單，或許未來能透過使用更複雜的模型、更複雜的前處理方法，例如取得更多的原始影像特徵，來提升冠狀動脈分割模型的效果。

在 CycleGAN 的模型訓練過程中，如何以量化的方式評估 CycleGAN 進行風格轉換的效果，目前尚是一個未解決的問題，或許未來能設計一個評估的演算法，如利用邊緣偵測方式評估心臟結構是否有被改變，以及利用影像 HU 值分布範圍來評估目前的影像為有、無顯影劑增強，使得 CycleGAN 結果能夠更加精確地被評估。

最後在相關應用的部分，目前提供的方法是以輔助醫師診斷為主，尚未能夠提供較全面的自動化流程，在鈣化位置偵測方面，目前需要手動輸入 HU 值範圍以進行鈣化位置的偵測，未來或許能透過無顯影劑資料預先計算受檢者的鈣化分數，並將其與有顯影劑資料偵測之鈣化位置計算的鈣化分數進行比較，或做為模型訓練的目標，訓練一個能直接找尋鈣化位置的模型，進而直接提供一個較準確的初始結果，減少手動調整的需求。而在狹窄度偵測方面，由於目前沒有取得血管狹窄相關的標註資料，因此尚未能直接對於血管狹窄的狀況進行偵測，而是僅能提供拉直後的血管影像、管徑趨勢等輔助判斷資料，若未來能取得相關標註資料，或許便能進一步以深度學習方式來解決此問題。